



**ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE**  

---

**FAKULTA BIOMEDICÍNSKÉHO INŽENÝRSTVÍ**  
**Katedra biomedicínské informatiky**

**Automatická klasifikácia častí tela na röntgenových  
snímkach pomocou neurónových sietí**

**Automatical classification of body parts in X-Ray  
images using neural networks**

Bakalářská práce

Studijní program: Informatika a kybernetika ve zdravotnictví

Studijní obor: Biomedicínska informatika

Autor bakalářské práce: Patrik Pejchal

Vedoucí bakalářské práce: Ing. Michal Reimer

---

**Kladno 2024**

## I. OSOBNÍ A STUDIJNÍ ÚDAJE

Příjmení: **Pejchal** Jméno: **Patrik** Osobní číslo: **498843**  
Fakulta: **Fakulta biomedicínského inženýrství**  
Garantující katedra: **Katedra informačních a komunikačních technologií v lékařství**  
Studijní program: **Informatika a kybernetika ve zdravotnictví**

## II. ÚDAJE K BAKALÁŘSKÉ PRÁCI

Název bakalářské práce:

**Automatická klasifikace částí těla v rentgenových snímcích pomocí neuronových sítí**

Název bakalářské práce anglicky:

**Automatical classification of body parts in X-Ray images using neural networks**

Pokyny pro vypracování:

Cílem bakalářské práce je klasifikace rentgenových snímků částí těla s využitím neuronových sítí. V rámci bakalářské práce se seznámte s metodami hlubokého učení, a jeho využití pro klasifikaci rentgenových obrazů. Navrhněte a na zkoumaném datasetu rentgenových snímků různých částí lidského těla otestujte různé metody a architektury neuronových sítí pro klasifikaci obrazů. Na základě prvotních výsledků se pokuste analyzovat možnou problematiku klasifikace jednotlivých zkoumaných tříd, se zaměřením se na kvalitu i kvantitu poskytnutých dat. Pokuste se pomocí různých metod tyto nedostatky eliminovat a co nejvíce tak zvýšit efektivitu výsledné klasifikace.

Seznam doporučené literatury:

- [1] Anwar, S.M., Majid, M., Qayyum, A. et al. , Medical Image Analysis using Convolutional Neural Networks: A Review, 10/2018, <https://doi.org/10.1007/s10916-018-1088-1>
- [2] Sarvamangala, D.R., Kulkarni, R.V. , Convolutional neural networks in medical image understanding: a survey., 2022, <https://doi.org/10.1007/s12065-020-00540-3>
- [3] Chlap, P., Min, H., Vandenberg, N., Dowling, J., Holloway, L. and Haworth, A. , A review of medical image data augmentation techniques for deep learning applications, 19 June 2021, <https://doi.org/10.1111/1754-9485.13261>

Jméno a příjmení vedoucí(ho) bakalářské práce:

**Ing. Michal Reimer**

Jméno a příjmení konzultanta(ky) bakalářské práce:

Datum zadání bakalářské práce: **14.02.2024**

Platnost zadání bakalářské práce: **20.09.2025**

doc. Ing. Karel Hána Ph.D.  
vedoucí katedry

prof. MUDr. Jozef Rosina, Ph.D., MBA  
děkan

## PROHLÁŠENÍ

Prohlašuji, že jsem bakalářskou práci s názvem „Automatická klasifikácia častí tela na röntgenových snímkach pomocou neurónových sietí“ vypracoval samostatně a použil k tomu úplný výčet citací použitých pramenů, které uvádím v seznamu přiloženém k bakalářské práci. Prohlašuji, že tato práce je přesnou kopií odevzdané elektronické verze.

Nemám závažný důvod proti užití tohoto školního díla ve smyslu § 60 Zákona č. 121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů.

V Kladně 7.5.2024

.....

Patrik Pejchal

## **POĎAKOVANIE**

Rád by som poďakoval vedúcemu mojej bakalárskej práce, Ing. Michalovi Reimerovi. Za cenné rady, za pomoc pri spracovaní tejto práce. Veľké ďakujem patrí mojej rodine, ktorý pri mne behom spracovania tejto bakalárskej práce stáli ako opora.

# **ABSTRAKT**

## **Automatická klasifikácia častí tela na röntgenových snímkach pomocou neurónových sietí**

Táto bakalárska práca skúma zlepšenie klasifikácie röntgenových snímok pomocou konvolučných neurónových sietí (CNN), ako sú VGG, ResNet, DenseNet a mnohé ďalšie, pričom sa zameriava na riešenie nevyváženosti tried a nedostatku údajov prostredníctvom váženia tried a rozširovania údajov. Cieľom týchto metód bolo zlepšiť diagnostickú presnosť a robustnosť modelov v lekárskom zobrazovaní. Štúdia preukázala, že váženie tried účinne riadi nerovnováhu tried, zatiaľ čo techniky rozšírenia zabraňujú nadmernému prispôsobeniu, čím sa zvyšuje zovšeobecniteľnosť a spoľahlivosť modelu. Tieto zistenia naznačujú, že ciele stratégie hlbokého učenia môžu výrazne zlepšiť výkonnosť CNN v lekárskej diagnostike, čo ponúka podstatné výhody pre klinické aplikácie.

## **Kľúčové slová**

Hlboké učenie, lekárske zobrazovanie, röntgenová klasifikácia, CNN, rozšírenie údajov, nerovnováha tried.

# **ABSTRACT**

## **Automatic classification of body parts in X-Ray images using neural networks**

This thesis explores the enhancement of X-ray image classification using Convolutional Neural Networks (CNNs) like VGG, ResNet, DenseNet and many more, focusing on addressing class imbalance and data scarcity through class weighting and data augmentation. These methods aimed to improve the diagnostic accuracy and robustness of models in medical imaging. The study demonstrated that class weighting effectively manages class imbalances, while augmentation techniques prevent overfitting, thus enhancing model generalizability and reliability. These findings suggest that targeted deep learning strategies can significantly improve CNN performance in medical diagnostics, offering substantial benefits for clinical applications.

## **Keywords**

Deep Learning, Medical Imaging, X-ray Classification, CNN, Data Augmentation, Class Imbalance.

# Obsah

<b>1. Úvod .....</b>	<b>5</b>
<b>2. Prehľad súčasného stavu.....</b>	<b>7</b>
2.1. História a vývoj lekárskeho zobrazovania .....	7
2.1.1. Raný vývoj v oblasti lekárskeho zobrazovania .....	7
2.1.2. Pokrok v zobrazovacích technológiách .....	9
2.1.3. Digitálna revolúcia .....	10
2.2. Výzvy pri analýze röntgenových snímok.....	12
2.2.1. Kvalita obrazu a šandardizácia.....	12
2.2.2. Interpretácia a odbornosť .....	13
2.2.3. Objem údajov .....	14
2.3. Hlboké učenie v lekárskom zobrazovaní .....	15
2.3.1. Úvod do hlbokého učenia.....	15
2.3.2. Úspešné projekty hlbokého učenia .....	17
2.3.3. Výzvy a obmedzenia .....	18
2.4. Prehľad existujúcich modelov hlbokého učenia.....	20
2.4.1. Konvolučné neurónové siete .....	20
2.4.2. Modely v klasifikácii röntgenových snímok .....	22
2.4.3. Inovácie a zlepšenia.....	24
2.4.4. Medzery a príležitosti pre výskum .....	25
<b>3. Ciele práce .....</b>	<b>27</b>
<b>4. Metodológia .....</b>	<b>29</b>
4.1. Relevantnosť súboru údajov a teoretická relevantnosť .....	29
4.2. Príprava a predbežné spracovanie údajov .....	31
4.3. Stratégie rozšírenia údajov .....	32
4.3.1. Zdôvodnenie augmentácie.....	32
4.3.2. Stratégie rozširovania údajov a ich vplyv na výkonnosť modelov ....	33
4.4. Výber modelu.....	34
4.5. Rámec hodnotenia .....	35
4.5.1. Hodnotiace parametre.....	35
4.5.2. Rozdelenie súboru údajov .....	36

<b>5. Implementácia.....</b>	<b>37</b>
5.1. Vykonávanie prípravy a rozširovania údajov.....	37
5.1.1. Implementácia predbežného spracovania.....	37
5.1.2. Použité techniky augmentácie .....	38
5.2. Spracovanie a delenie súborov údajov .....	40
5.2.1. Praktický prehľad a nastavenie súboru údajov .....	40
5.2.2. Proces rozdelenia.....	41
5.3. Modelový tréningový proces.....	41
5.3.1. Nastavenie tréningového prostredia .....	42
5.3.2. Vykonávanie tréningu modelu .....	42
5.3.3. Zvládanie výziev pri tréningu.....	44
5.4. Príprava na hodnotenie výkonnosti.....	44
5.4.1. Testovanie a hodnotenie modelov .....	44
5.4.2. Vizualizácia výkonu .....	45
<b>6. Výsledky.....</b>	<b>47</b>
6.1. Prehľad experimentálnych výsledkov .....	47
6.2. Experiment 1 - Účinnosť váh tried.....	47
6.3. Experiment 2 - Vplyv techník augmentácie údajov .....	49
6.4. Experiment 3 - Porovnávací analýza tréningu na pôvodných vs. pôvodných + rozšírených údajoch .....	51
<b>7. Diskusia.....</b>	<b>54</b>
<b>8. Záver .....</b>	<b>55</b>
<b>Zoznam použitej literatúry .....</b>	<b>56</b>
<b>Zoznam použitých obrázkov .....</b>	<b>60</b>



# 1. Úvod

Väčšina chorôb sa vo veľkej miere spolieha na zdravotnú diagnostiku a budúcnosť včasného zisťovania chorôb a vývoja liečby spočíva v rýchlo sa rozvíjajúcich oblastiach zdravotnej starostlivosti. Spomedzi všetkých metód používaných pri zobrazovaní je röntgenové zobrazovanie vo väčšine prípadov jednou z najpreferovanejších metód. Dôvodom je dostupnosť a výkonnosť, pretože ponúka základné detaily o vnútornej štruktúre ľudského tela. Interpretácia röntgenových snímok však stále zostáva veľmi odborne náročnou zložitou úlohou náchylnou na ľudské chyby. Práve tento fakt viedol k tomu, že sa v poslednom čase začali používať niektoré výpočtové technológie, ktoré využívajú umelú inteligenciu (AI) a strojové učenie, najmä hlboké učenie, s cieľom pomôcť zvýšiť presnosť a efektívnosť analýzy röntgenových snímok.

Hlboké učenie, podmnožina strojového učenia, preukázalo mimoriadny úspech v analýze lekárskeho snímok prostredníctvom použitia veľkých súborov údajov na trénovanie modelov, ktoré nakoniec detegujú, klasifikujú a lokalizujú patologické znaky s presnosťou, ktorá je porovnateľná alebo dokonca niekedy prevyšuje presnosť ľudských expertov [1]. V oblasti spracovania vizuálnych informácií sa konvolučné neurónové siete (CNN) stali jedným z modelov hlbokého učenia a vyberajú sa na mnohé úlohy v lekárskej diagnostike, ako je klasifikácia, segmentácia a vylepšovanie obrazu. To dokazuje, že hierarchické reprezentácie príznakov naučené z rozsiahlych neštruktúrovaných obrazových údajov sú prísľubom pre oblasť medicínskych obrazov, kde môže byť dôležitá extrakcia drobných narážok.

Napriek týmto pokrokom existuje niekoľko výziev pri aplikácii CNN na klasifikáciu röntgenových snímok. Jednou z mnohých výziev je nevyváženosť tried. Ide o jeden zo štandardných prípadov pre súbory lekárskeho údajov, v ktorých sú v porovnaní s ostatnými niektoré stavy extrémne nedostatočne zastúpené. Takáto nerovnováha môže spôsobiť skreslenie modelu, ktoré by mohlo viesť k dobrému výkonu pri častých stavoch, ale veľmi slabému výkonu pri zriedkavých stavoch. Ďalšou veľmi dôležitou výzvou je vlastne skutočnosť, že existuje nedostatok anotovaných lekárskeho snímok a väčšina rutinných modelov hlbokého učenia si vyžaduje veľké množstvo údajov, ak majú byť dosiahnuté špičkové výsledky.

Takéto problémy si vyžadujú veľmi robustné modely, ktoré dokážu dobre zovšeobecniť rozsiahle lekárske dáta, ktorých je často málo a sú rôznorodé. Táto práca sa preto zaoberá výzvou, ktorá hodnotí účinnosť metód hlbokého učenia pre klasifikačné úlohy röntgenových snímok, pričom osobitný dôraz sa kladie na to, ako by sa mohol znížiť problém nevyváženosti tried, resp. veľmi nevyváženého súboru údajov, aby bol takýto súbor údajov užitočnejší na tréning.

V tomto dokumente sú CNN robustnejšie a presnejšie pomocou nasledujúcich stratégií: začínajúc použitím váh tried na kompenzáciu nevyváženosti údajov a končiac technikami rozšírenia údajov na umelé zvýšenie tréňovaného súboru údajov s cieľom vniesť do modelov väčšiu variabilitu. Výskum má tri hlavné ciele: po prvé, posúdiť vplyv váh tried na vyhodnocovanie a riadenie nevyváženosti tried; po druhé, posúdiť vplyv rôznych techník rozšírenia údajov na zlepšenie výkonnosti modelov; a po tretie, porovnať výkonnosť CNN medzi tými, ktoré sú natrénované na pôvodných súboroch údajov, a tými, ktoré sú natrénované na pôvodných a rozšírených súboroch údajov. Cieľom daného výskumu je nájsť a preskúmať postupy a konfigurácie najlepšej klasifikácie röntgenových snímok pomocou najmodernejších architektúr CNN: VGG, ResNet a DenseNet a ďalšie.


## **2. Prehľad súčasného stavu**

### **2.1. História a vývoj lekárskeho zobrazovania**

V tejto kapitole sa opisuje transformačná cesta diagnostických zobrazovacích technológií od náhodného objavu röntgenových lúčov v roku 1895 až po digitálnu revolúciu na konci dvadsiateho storočia. Skúma prevratné pokroky, ako je vývoj počítačovej tomografie (CT), zobrazovania magnetickou rezonanciou (MRI) a nástup digitálnych zobrazovacích systémov. V každej časti sú vyzdvihnuté kľúčové inovácie a ich hlboký vplyv na lekársku diagnostiku, čo ilustruje, ako tieto technológie revolučne zmenili starostlivosť o pacientov a rozšírili možnosti lekárskej vedy.

#### **2.1.1. Raný vývoj v oblasti lekárskeho zobrazovania**

Jeden z najvýznamnejších objavov urobil v roku 1895 Wilhelm Röntgen (Obr. 1) - objav röntgenových lúčov -, ktorý znamenal revolučný skok pre vedu a následne aj pre medicínu. Röntgen pri práci s katódovými lúčmi spozoroval, že platínokyanid bária fluoreskuje na obrazovke, hoci prístroj bol chránený pred svetlom, a náhodne objavil röntgenové žiarenie. Všimol si, že pomocou týchto lúčov je možné preniknúť nielen cez pevné telesá vrátane ľudského tkaniva, ale aj zobrazit' vnútorné štruktúry metódami, ktoré nezasahujú do organizmu. Röntgen venoval pozornosť tomu, že lúče umožňujú vytvoriť obraz vnútornej štruktúry človeka, a zmienil sa o možnosti ich využitia v lekárskej diagnostike. [2]



Obrázok 1: Wilhelm Conrad Röntgen [3]

Krátko po objavení nového typu röntgenového žiarenia vytvoril Röntgen prvé röntgenové fotografie. Na jednej z nich bola jasne zobrazená ruka (Obr. 2); patrila jeho manželke, na ktorej bolo vidieť kosti a prsteň na jednom z prstov [4]. Táto ikonická snímka mala neskôr ukázať nielen potenciál röntgenových lúčov na vizualizáciu vnútorných štruktúr ľudského tela, ale mala vzbudiť veľký záujem a nadšenie vo vedeckej komunite a vlastne aj v širokej verejnosti. Schopnosť "vidieť" do vnútra tela bez chirurgického zákroku sa vnímala ako prelomový vývoj v lekárskej vede [2].




Obrázok 2: Prvá vytvorená röntgenová snímka [3]

Spočiatku sa používal na diagnostiku zlomenín kostí a lokalizáciu cudzích telies, napríklad pri strelných poraneniach. Krátko po ich objavení, o niekoľko týždňov neskôr, sa röntgenové lúče už používali na pomoc pri lekárskej diagnostike, čím sa ukázal ich okamžitý vplyv na medicínu pri napomáhaní liečbe a diagnostike. Toto nadšenie však rýchlo opadlo kvôli nebezpečenstvám, ktoré spôsobovalo nesprávne pochopenie a neidentifikované vystavenie radiačnému žiareniu, čo predstavovalo vážne prekážky a obmedzenia pre prvé aplikácie tejto technológie. [4]

### 2.1.2. Pokrok v zobrazovacích technológiach


Prechod od tradičných röntgenových prístrojov k počítačovej tomografii (CT) začiatkom 70. rokov 20. storočia znamenal obrovský skok v diagnostickom zobrazovaní. CT, ktoré zdokonalili Godfrey Hounsfield a Allan Cormack, ponúklo detailné priečne zobrazenie tela, ktoré bolo výrazne lepšie ako superponované snímky, ktoré mohli vytvoriť röntgenové lúče [5]. Táto technológia poskytla presnejší obraz vnútorných orgánov tela a ukázala sa ako celkom nápomocná pri identifikácii štruktúry mäkkých tkanív. Ovplyvnilo to najmä diagnostickú presnosť a tým ju výrazne zlepšilo.

Popri CT sa ako ďalšia prelomová technológia v lekárskom zobrazovaní objavila aj magnetická rezonancia (MRI) (Obr. 3). Založil ju Raymond Damadian a výrazne ju vylepšil Paul Lauterbur. Pomohla pri hľadaní snímok s vysokým rozlíšením vnútorných štruktúr tela pomocou magnetických polí a rádiových vln. Na rozdiel od röntgenových lúčov a počítačovej tomografie sa pri magnetickej rezonancii nepoužíva ionizujúce žiarenie. Bol to veľký prelom v oblasti bezpečnosti pacientov. Vďaka tomu sa MRI stala užitočnou najmä v neurológii, onkológii a pri diagnostike ochorení pohybového aparátu, pretože poskytovala jasnejší kontrast medzi rôznymi druhmi tkanív, hoci neexistujú rozdiely v ich hustote. [5]



Obrázok 3: Príklad snímky hrudníka CT a MRI [6]

Ultrazvuková technológia (Obr. 4) sa vyvinula od najjednoduchšej formy až po zložitejšie digitálne systémy, ktoré poskytujú jasné a zároveň spoľahlivé obrazy [7]. Najnovšie technológie, napríklad vývoj prenosných ultrazvukových prístrojov, poskytl ľuďstvu ešte rozsiahlejšie využitie ultrazvukového zobrazovania v rôznych odboroch.



Obrázok 4: Príklad ultrazvuku pľúc [8]

Takéto zariadenia pomáhajú rozvíjať okamžité diagnostické možnosti aj vo vzdialených alebo zdrojovo obmedzených prostrediach a rozširujú rozsah diagnostickej praxe, čo v konečnom dôsledku pomáha zlepšovať starostlivosť o pacientov. Tieto zobrazovacie metódy - CT, MRI, pokročilá ultrasonografia - každá z nich načrtla spektrum gigantických technologických krokov, ktoré bolo potrebné urobiť, a mali obrovský vplyv na diagnostickú medicínu. Každá metóda sa vo väčšine prípadov navzájom dopĺňa, čím ponecháva v rukách lekára mocné nástroje na stanovenie ešte účinnejšej diagnózy a zavedenie vhodného liečebného postupu pri chorobách.

### 2.1.3. Digitálna revolúcia

Posledné dve dekády 90. rokov a samotné 90. roky boli svedkami niektorých z najvýznamnejších technologických zmien v oblasti lekárskeho zobrazovania, keďže výpočtová technika a digitálne úložiská priniesli nový trend, ktorý viedol k rozvoju digitálneho zobrazovania. Spočiatku sa táto zmena stretávala s veľkou nedôverou zo strany lekárskeho odborníkov kvôli nákladom, ktoré s tým súviseli, a tiež kvôli tomu, že táto technológia bola nová. Nové výhody, ktoré prinášala zvýšená kvalita obrazu a možnosť jednoduchšej manipulácie s obrazom, však boli neprehliadnuteľné, a tak došlo k jej všeobecnému prijatiu. Kľúčovými míľnikmi v rámci rádiológie bolo zavedenie počítačovej rádiografie a PACS (Picture Archiving and Communication Systems) - integrovaného systému rôznych zobrazovacích metód do jednotného systému, ktorého cieľom je zefektívniť pracovný postup v zdravotníckych zariadeniach. [9]

Revolúcia digitálnych médií výrazne ovplyvnila archiváciu a vyhľadávanie lekárskeho snímok. Nahradenie používania objemných fyzických materiálov digitálnymi formátmi okrem iného zvýšilo efektívnosť pri manipulácii so snímkami [10]. Digitálne databázy umožnili jednoduchšiu manipuláciu a rýchlejšie vyhľadávanie ako tradičné archívy, čo spôsobilo revolúciu v pracovnom procese lekárskeho zobrazovania. Vývoj viedol k rýchlemu zvýšeniu prístupu k záznamom o pacientoch, čím sa skrátil časový harmonogram diagnostiky a liečby.

Systémy PACS definitívne zmenili prostredie zdravotnej starostlivosti tým, že integrovali rôzne zobrazovacie techniky, zlepšili pracovné postupy a dokonca aj interoperabilitu zdravotných záznamov. Integrácia priniesla veľké zlepšenie v spôsobe poskytovania zdravotnej starostlivosti a starostlivosti o pacientov, umožnila rýchle stanovenie diagnózy a obmedzila oneskorenia spojené s fyzickým presunom snímok. Možnosť vzdialenej dostupnosti snímok ďalej zlepšila komunikáciu zdravotníckych pracovníkov a bola rozhodujúca pre globalizáciu telemedicíny. V tomto období umelej inteligencie a telemedicíny sa význam digitálneho zobrazovania mnohonásobne zvýšil. [11]

Telemedicina podporuje konzultácie a diagnostiku na diaľku, čím sa prístup k lekárskej expertíze posúva za geografické hranice. Integrácia umelej inteligencie s digitálnym zobrazovaním ďalej integrovala revolučné zmeny v analýze obrazu na zvýšenie diagnostickej presnosti a prediktívnej analýzy. Aplikácie umelej inteligencie v lekárskom zobrazovaní, ako napríklad automatická detekcia a diagnostika, naďalej napredujú a vykazujú pozitívny vplyv na výsledky liečby pacientov tým, že pomáhajú pri včasných a presných rozhodnutiach o liečbe. [10]

Všetky tieto poznatky spoločne poukazujú na transformačný vplyv digitálneho zobrazovania na medicínu, pretože znamenajú posun od pôvodného dôrazu v tejto oblasti na vytváranie a získavanie snímok k praktickejšiemu, oveľa cielenejšiemu zameraniu na spracovanie, organizáciu a interpretáciu lekárskeho snímok.

## **2.2. Výzvy pri analýze röntgenových snímok**

V tejto kapitole sa skúmajú mnohostranné výzvy a inovácie pri dosahovaní vysokokvalitných röntgenových snímok, ktoré sú kľúčové pre spoľahlivú diagnostiku. Rozoberá faktory ovplyvňujúce kvalitu snímok vrátane použitých technológií, odborných znalostí technikov a podmienok prostredia v zobrazovacích zariadeniach. Okrem toho sa v kapitole skúmajú ťažkosti pri šandardizácii röntgenových protokolov v rôznych zdravotníckych zariadeniach v dôsledku rôznorodého vybavenia a absencie univerzálnych zobrazovacích noriem. Tieto zložitosti zdôrazňujú význam nepretržitého vzdelávania, modernizácie vybavenia a prísnej šandardizácie na zvýšenie diagnostickej presnosti a starostlivosti o pacientov.

### **2.2.1. Kvalita obrazu a šandardizácia**

Dosiahnutie vysokej kvality röntgenových snímok závisí od viacerých faktorov vrátane technologických možností a stavu zariadenia, rozdielov medzi výrobcami a odbornosti technikov, ktorí tieto systémy obsluhujú [12]. Je veľmi dôležité, aby technici boli riadne vyškolení a skúsení, aby sa optimalizovalo používanie röntgenových prístrojov a zabezpečilo sa správne zachytenie a interpretácia snímok. Okrem toho podmienky prostredia v zobrazovacích zariadeniach, ako je nastavenie miestnosti a postupy priebežnej údržby, významne ovplyvňujú jasnosť a detailnosť röntgenových snímok, čo zdôrazňuje dôležitosť udržiavania dobre nastaveného zobrazovacieho prostredia [13].

Šandardizácia protokolov röntgenového zobrazovania v rôznych zdravotníckych zariadeniach, ako sú malé kliniky až po veľké nemocničné systémy, prináša značné výzvy. Dôvodom je predovšetkým absencia univerzálnych noriem kvality snímok, čo vedie k variabilite, ktorá môže ovplyvniť diagnostické postupy a potenciálne viesť k nesprávnej interpretácii röntgenových snímok, a tým ovplyvniť starostlivosť o pacientov a diagnostickú spoľahlivosť.

Šandardizačné úsilie navyše komplikuje rôznorodosť röntgenových zariadení používaných v rôznych inštitúciách. Široká škála modelov a technológií, z ktorých každá má jedinečné špecifikácie a zobrazovacie schopnosti, sťažuje zavedenie jednotnej normy. Modernizácia starších zariadení s cieľom zosúladiť ich s modernými štandardmi si často vyžaduje značné finančné investície a spoločné úsilie na zabezpečenie kompatibility rôznych zariadení a generácií technológií, čo je nevyhnutné pre konzistentné a presné diagnostické zobrazovanie. [13]



Tieto faktory spoločne poukazujú na zložitosť udržiavania štandardov zobrazovania v zdravotníctve. Riešenie týchto výziev prostredníctvom komplexnej odbornej prípravy, efektívneho riadenia zobrazovacieho prostredia a prísnej štandardizácie protokolov je nevyhnutné na zvýšenie kvality a konzistentnosti röntgenovej diagnostiky v rôznych zdravotníckych zariadeniach.

### **2.2.2. Interpretácia a odbornosť**

V súčasnej situácii v oblasti zdravotnej starostlivosti je úloha rádiológie nenahraditeľná. Bez špecifických odborných znalostí rádiológov pri interpretácii zložitých röntgenových snímok by detaily, ktoré sú kľúčom k diagnóze, zostali z pohľadu bežného diagnostika nejasné. Na druhej strane to zahŕňa zložitosti spojené s hlbokým pochopením anatómie, choroby a klinických súvislostí. Nakoniec, pri všetkých týchto zručnostiach sú rádiológovia zraniteľní voči ľudským chybám, ako je únava, kognitívne skreslenia a vplyvy veľkého množstva práce, ktoré ich môžu prinútiť dopustiť sa chýb pri stanovení diagnózy. Táto skutočnosť zdôrazňuje potrebu neustáleho vzdelávania a dosť možno aj prijatia moderných technológií, ktoré pomôžu znížiť chybovosť. [14]

K týmto výzvam sa pridáva celosvetový nedostatok vyškolených rádiológov, najmä v regiónoch s obmedzenými zdravotníckymi zdrojmi. Čakacie lehoty na potrebné lekárske zákroky a oneskorenia v diagnostike potom ďalej prispievajú k obmedzeniu starostlivosti o pacientov. Vo väčšine krajín vrátane Mongolska [15] a Malajzie [16] znížený pomer počtu rádiológov k počtu obyvateľov ďalej zaťažuje systém zdravotnej starostlivosti, pričom na existujúcich rádiológov je vyvíjaný vysoký tlak a existuje vysoký potenciál pre výskyt narastajúcich diagnostických chýb. Táto situácia preto zdôrazňuje potrebu strategických plánov vzdelávania a nasadenia rádiológov, ktoré využívajú účinnejšie diagnostické postupy, ako je telerádiológia, zamerané na zmiernenie dopadov, ktoré môže takýto nedostatok spôsobiť.

Dôsledky týchto zložených problémov sú významné a siahajú na kvalitu starostlivosti o pacientov po celom svete. To by teda malo za následok zlý zdravotný výsledok, a teda zlý prístup k službám vysokokvalifikovaných rádiológov a vysokú chybovosť znásobenú rozdielmi v zdravotnej starostlivosti. To odôvodňuje medzinárodné partnerstvo na riešenie tohto deficitu a na posilnenie a dokonca ďalší rozvoj kapacít rádiologických služieb na celom svete, aby sa zabezpečilo, že nové rádiologické technológie a techniky sa dostanú do širokého prostredia zdravotnej starostlivosti. Medzi ďalšie riešenia, ktoré je potrebné zaviesť, patria lepšie programy odbornej prípravy, podpora kontinuálneho odborného rozvoja, telerádiológia a umelá inteligencia, aby sa rádiologické služby stali presnejšími a efektívnejšími, čo v konečnom dôsledku pomôže globálnej starostlivosti o pacientov.

### **2.2.3. Objem údajov**

Medzi hlavné dôvody nárastu súborov údajov patrí technologický vývoj v oblasti zobrazovacích systémov, rastúci trend v zobrazovacích postupoch a širšie uplatňovanie skríningových programov.

V tomto kontexte je potrebné venovať pozornosť skutočnosti, že používanie moderných technológií a nástrojov v oblasti zdravotnej starostlivosti zvýšilo množstvo vytvorených obrazových údajov na doteraz nevídanú úroveň. Moderné viacrezové CT skenery a prístroje MRI s vysokým rozlíšením produkujú súbory údajov, ktoré sú podstatne väčšie ako súbory, ktoré vytvárali ich staršie ekvivalenty. [17]

Tento veľký objem obrazových údajov tak vytvára silný tlak na systémy zdravotnej starostlivosti a najmä na infraštruktúru na ukladanie, vyhľadávanie a údržbu údajov. Toto zvýšené zaťaženie údajmi by mohlo nahromadiť neefektivitu v pracovnom procese, problémy s prístupom k údajom a vyššie riziko porušenia ochrany údajov. Takéto ohromujúce objemy zaťažujú zdravotnícke zariadenia, aby ich zvládli, a pritom je len logické, že systémy riadenia údajov musia byť veľmi silné. Riešením týchto potrieb sú technológie, ako cloudové úložiská, techniky kompresie údajov, pokročilé databázové systémy vyvinuté pre veľké objemy údajov a ďalšie škálovateľné riešenia, ktoré sú navrhnuté a aplikované s rastúcim dopytom. [18]

Okrem toho si ďalšie fungovanie systému vyžaduje sofistikovanú analytiku a umelú inteligenciu (AI) na správu a analýzu týchto rozsiahlych súborov údajov. Umelá inteligencia a strojové učenie pomáhajú pri automatizácii analýzy obrazu, umožňujú rýchlu a presnú diagnostiku, čo vedie k lepšiemu rozhodovaniu [17]. K výraznému zlepšeniu došlo v niektorých špecifických aplikáciách umelej inteligencie týkajúcich sa práce s veľkými súbormi obrazových údajov a ich interpretácie - napríklad rozpoznávanie vzorov a detekcia anomálií v rámci snímok. Tieto nástroje slúžia na automatizáciu správy údajov a zároveň pomáhajú rádiológom presnejšie a rýchlejšie obslúžiť pacientov.


To všetko zdôrazňuje naliehavú potrebu inovatívnych riešení na riadenie rastúcich požiadaviek na údaje v lekárskom zobrazovaní, aby zdravotnícke systémy mohli naďalej poskytovať kvalitnú, efektívnu a bezpečnú starostlivosť o pacientov.

## **2.3. Hlboké učenie v lekárskom zobrazovaní**

V tejto kapitole sa skúma významný vplyv hlbokého učenia na lekársku diagnostiku, pričom sa zdôrazňuje jeho schopnosť zvýšiť presnosť a účinnosť detekcie a analýzy chorôb v rôznych špecializáciách. Rozoberajú sa v nej výzvy súvisiace so závislosťou od údajov a etickými aspektmi, pričom sa zdôrazňuje potreba starostlivej integrácie a dodržiavania právnych predpisov s cieľom plne využiť potenciál umelej inteligencie v zdravotníctve.

### **2.3.1. Úvod do hlbokého učenia**

Hlboké učenie je súčasťou podmnožiny strojového učenia (Obr. 5), ale s neporovnateľnou schopnosťou komplexne spracovať obrovské množstvo údajov prostredníctvom mnohých vrstiev abstrakcie, čím napodobňuje funkcie ľudského mozgu. Kým tradičné strojové učenie sa často spoliehalo na manuálnu extrakciu funkcií, hlboké učenie spôsobilo revolúciu vďaka automatizácii prostredníctvom architektúr vrstvených neurónových sietí. Tieto siete pozostávajú z neurónov vo vrstvách, ktoré komunikujú prostredníctvom prepojených uzlov, čím simulujú spôsob, akým sa informácie spracúvajú v biologických mozgoch. [19]



Obrázok 5: Rozdiel medzi hlbokým a strojovým učenie [20]

Možnosti hlbokého učenia ďaleko prevyšujú možnosti bežného strojového učenia, najmä pokiaľ ide o spracovanie veľkého objemu dát [21]. S nárastom aplikácií náročných na dáta, napríklad rozpoznávanie obrazu a spracovanie prirodzeného jazyka, hlboké učenie prekonáva väčšinu existujúcich prístupov vo výpočtovej efektivite a presnosti. Hĺbkové učenie umožňuje jemnejšie a detailnejšie pochopenie a interpretáciu údajov, a preto dokáže prekonať predchádzajúce algoritmy v rýchlosti a sofistikovanosti.

Veľké súbory údajov sú navyše zdrojom tréningu, ktorý umožňuje vytvárať modely hlbokého učenia a autonómne ich zdokonaľovať. Najlepšie to dokazujú konvolučné neurónové siete (CNN), ktoré si výnimočne dobre počínajú napríklad pri úlohách klasifikácie obrázkov a detekcie objektov. CNN, podobne ako mnohé iné architektúry hlbokého učenia, sa automaticky učia extrahovať podstatné vlastnosti z údajov, pričom tento proces sa zlepšuje, keď je k dispozícii väčšie množstvo tréningových údajov [22].

Vďaka tejto schopnosti samoučenia je hlboké učenie mimoriadne vhodné pre všetky aplikácie, kde neustále pribúdajú nové údaje, čo umožňuje modelu vyvíjať sa a prispôbovať sa týmto novým informáciám v priebehu času. Stručne povedané, hlboké učenie je pravdepodobne najinovatívnejším pokrokom v oblasti umelej inteligencie, ktorá sa dokáže učiť a dokonca rozhodovať na základe veľkých súborov údajov. To, čo ho odlišuje, sú intenzívne neurónové siete, ktoré sú nastavené na automatizáciu procesov extrakcie funkcií a rozhodovania, čím sa robí obrat od konvenčných metód učenia k niečomu oveľa dynamickejšiemu a prispôbivejšiemu.

### 2.3.2. Úspešné projekty hlbokého učenia

Pokiaľ ide o techniky hlbokého učenia, používanie konvolučných neurónových sietí (CNN) spôsobilo revolúciu v lekárskej diagnostike v rôznych špecializáciách, či už ide o oftalmológiu, onkológiu alebo kardiológiu alebo ďalšie.

Diagnostika diabetickej retinopatie: U diabetickej retinopatie, jednej z hlavných príčin slepoty u ľudí s cukrovkou, sa výrazne zlepšila detekcia vďaka modelom hlbokého učenia. Vďaka nemu dokážu CNN zistiť jemné vzory na snímkach sietnice, ktoré indikujú ochorenie, ktoré však ľudský pozorovateľ nemusí rozpoznať. Napríklad štúdia Alexandra Rakhlina, 2018 [23] s využitím hlbokého učenia dosiahla až 99 % citlivosť a 71 % špecifickosť, hodnotu plochy pod krivkou (AUC) 0,97, čím okrem iného prekonal diagnostickú presnosť, ktorú dosahujú niektorí vyškolení optometristi. To odráža prísľub AI pre hlboké učenie na zvýšenie účinnosti a pokrytia v skríningových programoch.

Zisťovanie a klasifikácia rakoviny: Technológia hlbokého učenia môže zohrávať úlohu v úsilí o zlepšenie kvality života vďaka tomu, že pomôže odhaliť a klasifikovať rakovinu. Hlboké učenie ukázalo mnoho potenciálov smerom k pokroku v detekcii a klasifikácii rakoviny, napríklad rakoviny prsníka, z rôznych obrázkov. Čo je dôležitejšie, je tiež cenné zdôrazniť, že tieto modely konkrétne poskytovali rýchlejšiu a presnejšiu rýchlosť merania v porovnaní s tradičnými metódami prostredníctvom prístupov komplexného tréningu. Hlboké učenie bude skutočne schopné dosiahnuť pôsobivú úroveň detekcie využitím veľkých tréningových súborov údajov, či už plne klinicky anotovaných, alebo len so značkami na úrovni obrazu. Napríklad v jednej zo štúdií od Li Shena a spoluautorov, 2019 [24] na databáze INbreast na známom úložisku snímok FFDM (Full-Field Digital Mammography), najlepší jednotlivý model hlbokého učenia vykazoval pôsobivú AUC na úrovni 0,95. Pri štyroch modeloch dosiahla AUC hodnotu 0,98 a citlivosť bola 86,7 % a špecifickosť 96,1 % v skupine výsledkov s kombináciou. To poukazuje na potenciálnu úlohu, ktorú by hlboké učenie mohlo zohrávať pri umožňovaní skoršieho a presnejšieho odhaľovania zhubných nádorov, čo je rozhodujúce nielen pre správne plánovanie a liečbu, ale aj pre zvýšenie miery prežitia vďaka lepšej diagnostike.

Analýza zobrazovania srdca: Hlboké učenie prinieslo revolúciu do kardiologickej starostlivosti tým, že umožňuje lepšie posúdenie funkcie a štruktúry srdca oveľa účinnejším a efektívnejším spôsobom ako tradičné metódy. Z ľudského hľadiska dáva automatizácia takýchto analýz pri zobrazovaní srdca istotu presnosti a šance na včasné odhalenie akejkoľvek anomálie v srdci na presný zásah liečby. Jedným z veľkých atribútov hlbokého učenia v tomto postupe - proces segmentácie snímok srdca, ktorý je základným nástrojom lekárov na veľmi presnú diagnostiku stavu srdca - je zefektívnenie pracovných postupov pre pacientov. [25]

Integrácia hlbokého učenia výrazne zmenila medicínske zobrazovanie pre klinickú prax. Tieto technologické prelomy prispievajú k ešte väčšej automatizácii strašne prácnych a opakujúcich sa úloh spojených s analýzou obrazu, čím uberajú neoceniteľný čas a pozornosť odborníkov, ktorí ich namiesto toho musia venovať komplikovanejším analýzám prípadov. Všetky tieto vylepšenia trocha zvyšujú efektívnosť klinického pracovného postupu, ale čo je dôležitejšie, znižujú pravdepodobnosť diagnostických chýb. Inými slovami, modely hlbokého učenia poskytujú presné poznatky, ktoré zvýšia presnosť diagnostiky a pomôžu pri lepšom manažmente pacienta, čím sa výrazne zlepšia výsledky starostlivosti o pacientov v rôznych lekárskejších špecializáciách.

### **2.3.3. Výzvy a obmedzenia**

Hlboké učenie spôsobilo revolúciu v tejto oblasti tým, že výrazne zlepšilo schopnosť diagnostikovať choroby a analyzovať lekárske snímky, nehovoriac o potenciáli predpovedať prognózu pacienta. Tieto modely sú však aj naďalej závislé od rozsiahlych, vysokokvalitných anotovaných súborov údajov na ich tréning, a preto stále predstavujú významnú výzvu. Zhromažďovanie a anotácia takýchto údajov si vyžiada veľa úsilia, zručností a zdrojov - niečo, čo sa zvyčajne komplikuje otázkami ochrany súkromia a rozmanitosti údajov potrebných na zabránenie skreslenia. Modely vyškolené na základe údajov bez rôznorodosti môžu zlyhať pri dosahovaní primeraných výsledkov v rôznych demografických skupinách, čo môže viesť k rozdielom vo výsledkoch zdravotnej starostlivosti. [26]

To na druhej strane spôsobuje, že problémy s interpretovateľnosťou a dôveryhodnosťou modelov hlbokého učenia sú ešte oveľa náročnejšie. Inými slovami, zdravotnícki pracovníci budú implementovať rozhodnutia generované umelou inteligenciou do klinickej praxe len vtedy, ak budú mať vysokú úroveň porozumenia a dôvery v umelú inteligenciu - možno dokonca väčšiu ako v samotné rozhodnutia. Nepriehľadné, t. j. netransparentné modely rozhodovacích procesov sú stále významnou prekážkou väčšej akceptácie modelov hlbokého učenia. Ide o klasickú požiadavku pri vývoji vysvetľujúcich modelov hlbokého učenia (EDLM), pretože ich cieľom je urobiť rozhodovací proces umelej inteligencie oveľa transparentnejším, zrozumiteľnejším a klinicky súvisiacim [27]. Tie sa zasa usilujú poskytovať lekárom nielen presné, ale aj interpretovateľné poznatky, čo je pre získanie dôvery a umožnenie klinického prijatia celkom zásadné.

V popredí musia byť etické aspekty - ochrana osobných údajov pacientov a algoritmická zaujatosť. Zabezpečenie etického používania umelej inteligencie v zdravotníctve by znamenalo dodržiavanie najprísnejších zákonov o ochrane údajov, pravidelné vykonávanie kontrol zaujatosti a spoluprácu s etikmi, ktorí by ich previedli morálnym bludiskom, ktoré umelá inteligencia prináša. Tieto opatrenia sú nevyhnutné na zachovanie integrity informácií o pacientoch a vytvorenie spravodlivých podmienok pre zdravotnú starostlivosť. [26]

Okrem toho je potrebné riešiť regulačné a integračné problémy s cieľom zabezpečiť úspešnú implementáciu technológií v klinických podmienkach. Medzi dôležité výzvy patrí súlad s lekáorskými normami a regulačnými schváleniami, ktoré môžu pôsobiť ako prekážky pri hladkej integrácii do každodenného klinického používania. K tomu sa pridáva zabezpečenie technickej integrácie, aby sa systémy umelej inteligencie dobre spájali a koexistovali s už existujúcimi IT systémami v zdravotníctve s cieľom zabezpečiť, aby ich prijatie neovplyvnilo pracovný tok. To si bude vyžadovať spoluprácu medzi vývojármi AI, zdravotníckymi pracovníkmi a regulačnými orgánmi, aby sa zabezpečilo, že vyvinuté nástroje hlbokého učenia prinesú do zdravotnej starostlivosti pridanú hodnotu, a nie veci skomplikujú.

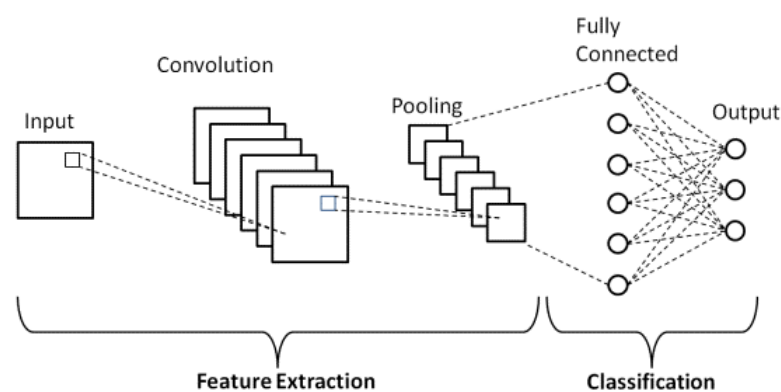
Všetky tieto faktory spoločne naznačujú, že oblasť nasadenia hlbokého učenia v zdravotníctve je rozsiahla a trochu zložitá, s mnohými potenciálnymi príslubmi, ale aj s mnohými možnými nástrahami, ktoré je potrebné opatrne obísť, aby sa naplno využil potenciál umelej inteligencie v zdravotníctve.

## 2.4. Prehľad existujúcich modelov hlbokého učenia

Táto kapitola sa zaoberá kľúčovou úlohou konvolučných neurónových sietí (CNN) v oblasti hlbokého učenia, pričom zdôrazňuje najmä ich účinnosť pri spracovaní a analýze vizuálnych údajov. Skúma, ako architektúra CNN - pozostávajúca z konvolučných, združených a plne prepojených vrstiev - umožňuje komplexné úlohy analýzy obrazu, čím spôsobuje revolúciu v oblastiach, ako je rozpoznávanie tváre, autonómna navigácia vozidiel a lekárska diagnostika. Kapitola sa zaoberá aj širšími dôsledkami a výzvami použitia týchto modelov v reálnych aplikáciách, pričom zdôrazňuje ich transformačný vplyv na to, ako stroje vnímajú vizuálny svet a komunikujú s ním.

### 2.4.1. Konvolučné neurónové siete

Najúspešnejšími a najpoužívanejšími technikami v rámci hlbokého učenia sú konvolučné neurónové siete (CNN) práve vďaka analytickému spracovaniu vizuálnych údajov. V architektúre zahŕňa konvolučné vrstvy, vrstvy združovania a plne prepojené vrstvy (Obr. 6). Každá z týchto vrstiev má rozhodujúcu úlohu pri schopnosti siete vykonávať úlohy komplexnej analýzy obrazu. Konvolučné vrstvy aplikujú na vstupné obrazy niekoľko filtrov a vytvárajú mapy príznakov, ktoré by vyjadrovali dôležité informácie, napríklad hrany alebo textúry. Združovacie vrstvy zmenšujú priestorové rozmery týchto príznakových máp. Počet potrebných parametrov a výpočtov sa teda výrazne zníži, čo zvyšuje efektívnosť výpočtov siete a pomáha jej, aby nebola nadmerne prispôbená. Plne prepojené vrstvy skombinovali tieto prvky, aby získali konečný výstup buď na klasifikáciu, alebo na iné formy predpovedí. [28]

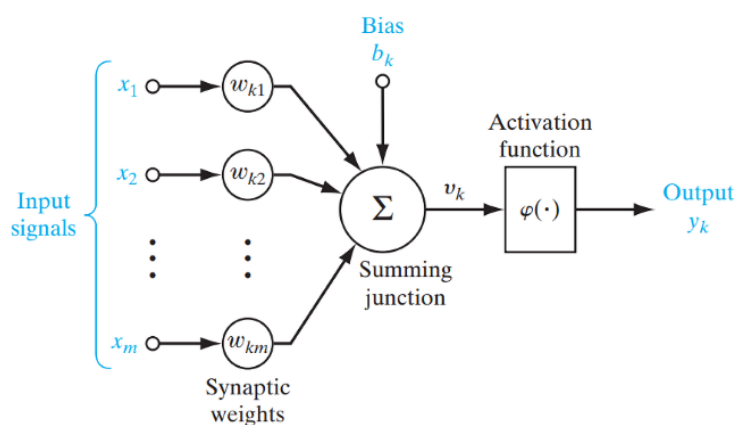


Obrázok 6: Architektúra CNN modelu [29]



Sila CNN pri spracovaní vizuálnych údajov je založená na ich konštrukcii, ktorá napodobňuje niektoré správanie centra ľudského oka. Neuróny CNN reagujú na prekrývajúce sa oblasti vo vizuálnom poli, čím definujú lokálne recepčné polia, ktoré pomáhajú zachytiť priestorové a časové závislosti. Táto konštrukcia preto umožňuje sieti zachovať citlivosť na dané prvky bez ohľadu na ich umiestnenie vo vstupnom obraze, čo vedie k translačnej invariantnosti, ktorá je veľmi dôležitá pri úlohách, kde orientácia a poloha objektov majú značný rozptyl. [30]

CNN tiež používajú spoločné váhy a odchýlky (Obr. 7). Tým sa znižuje zložitosť modelu a počet parametrov, čím sa zvyšuje jeho výpočtová dostupnosť, ako aj ďalej znižuje riziko pretrénovania [28]. CNN dramaticky zmenili potenciál systémov v praktických oblastiach použitia, ako je napríklad rozpoznávanie tváre, autonómna navigácia vozidiel a medicínska obrazová diagnostika. V systéme autonómneho riadenia sa CNN používajú na zlepšenie interpretácie cez dopravné značky, prekážky atď. a tým zvyšujú súčasnú bezpečnosť a spoľahlivosť samočinného systému [31]. CNN v medicínskom zobrazovaní prispievajú k včasnej detekcii rakoviny a kategorizácii rôznych druhov rakoviny na základe obrazových skenov, čím zlepšujú presnú diagnostiku a v konečnom dôsledku vedú k efektívnemu plánovaniu terapie [32].



Obrázok 7: Váhy a odchýlky v neurónoch [33]

Tieto aplikácie sú výzvou, ktorá poukazuje na to, že model hlbokého učenia dokáže rozpoznať a interpretovať niektoré veľmi zložité vzory vo vizuálnych údajoch niekedy ešte presnejšie, než je úroveň ľudských schopností. Čo otvorilo cestu k prelomu vo výkonnosti a efektívnosti vo veľkej miere prostredníctvom všeobecného vývoja a aplikácie CNN v rozpoznávaní obrazu a súvisiacich oblastiach; všeobecný vývoj a aplikácia CNN v rozpoznávaní obrazu zásadne zmenili spôsob, akým stroje vnímajú vizuálny svet a komunikujú s ním. Tento technologický pokrok podporuje širokú škálu aplikácií, ktoré vedú k významnému vplyvu nielen v priemysle, ale aj v každodennom živote; znamená to schopnosť umelej inteligencie výrazne posilniť interakciu medzi človekom a strojom.


#### **2.4.2. Modely v klasifikácii röntgenových snímok**

Modely hlbokého učenia vrátane konvolučných neurónových sietí (CNN), reziduálnych sietí (ResNets) a U-Net sa stali nenahraditeľnými nástrojmi pri klasifikácii röntgenových snímok, čím spôsobili revolúciu v lekárskej diagnostike.

CNN sú základom pre úlohy klasifikácie obrázkov, využívajú vrstvy konvolučných filtrov na automatickú detekciu základných vlastností, ako sú hrany, tvary a textúry, ktoré sú kľúčové pre pochopenie zložitých lekárskeho obrázkov, ako sú napríklad röntgenové snímky. Táto architektúra obohatená o aktivačné funkcie, ako sú ReLU a vrstvy združovania, efektívne spracováva pixelové údaje a zároveň znižuje dimenzionalitu a výpočtové zaťaženie, čím zvyšuje presnosť extrakcie príznakov. [34]


ResNet (Obr. 8) rieši problém tréningu hlbokých neurónových sietí zavedením preskokových spojení, ktoré zmierňujú problém miznúceho gradientu, čo umožňuje úspešné tréningovanie oveľa hlbších sietí. Tým, že ResNet umožňuje opakované použitie funkcie a zachováva tok informácií cez po sebe idúce vrstvy, vynikajú pri zachovávaní presnosti a zachytávaní zložitých vzorov v lekárskeho snímkach. Ich prispôsobivosť zložitým diagnostickým úlohám ich robí neoceniteľnými pri klasifikácii röntgenových snímok, kde sú presnosť a hĺbka analýzy prvoradé. [35]

## Residual Networks



Obrázok 8: ResNet model [36]

Siete U-Net (Obr. 9), pôvodne navrhnuté na segmentáciu biomedicínskych snímok, ponúkajú výnimočné schopnosti pri segmentácii snímok na jednotlivé časti, čo uľahčuje presnú lokalizáciu abnormalít na röntgenových snímkach. Jedinečná architektúra v tvare písmena "U", ktorá pozostáva zo zužujúcej sa cesty na zachytenie kontextu a rozširujúcej sa cesty na presnú lokalizáciu, umožňuje sieťam U-Net dosahovať vysokú presnosť aj pri obmedzených anotovaných údajoch, vďaka čomu sa stávajú nepostrádateľnými v úlohách lekárskeho zobrazovania. [37]



Obrázok 9: U-Net model [38]

Tieto modely sú obzvlášť vhodné na klasifikáciu röntgenových snímok, pretože efektívne spracúvajú veľké množstvá údajov typických pre lekárske snímky a učia sa na základe komplexných vzorcov prítomných v lekárskej diagnostike. Znižujú závislosť od ľudského vstupu a zlepšujú schopnosť automatizovať detekciu a klasifikáciu rôznych medicínskych stavov, čo výrazne pomáha pri diagnostike a plánovaní liečby.

### 2.4.3. Inovácie a zlepšenia

Tieto nedávne pokroky v oblasti hlbokého učenia zvýšili presnosť a rýchlosť diagnostikovania chorôb z lekárskeho snímkov pomocou sofistikovaných modelov a hardvérových zlepšení spôsobu diagnostikovania.

Zvýšenie presnosti pri detekcii chorôb: To je hlavný dôvod, prečo sa v najnovších architektúrach neurónových sietí navrhla ECA-DenseNet (Efficient Channel Attention-DenseNet) na spresnenie rozlišovania medzi benígnymi a malígnymi nádormi. Napríklad v práci od AYDIN, Halise Nur a Oktay YILDIZ, 2023 [39] sa preukázalo, že klasifikačná presnosť modelu ECA-DenseNet je veľmi sľubná a dosahuje 95,07 %, čím sa efektívne demonštruje možnosť účinnej extrakcie z významných znakov hustých spojení vynechaním informácií mimo miesta. Táto vyššia úroveň detailov je preto celkom zásadná pre presnú diagnózu a presnejšie plánovanie liečby, čím sa znižuje riziko nesprávnej diagnózy so všetkými jej pravdepodobnými dôsledkami.

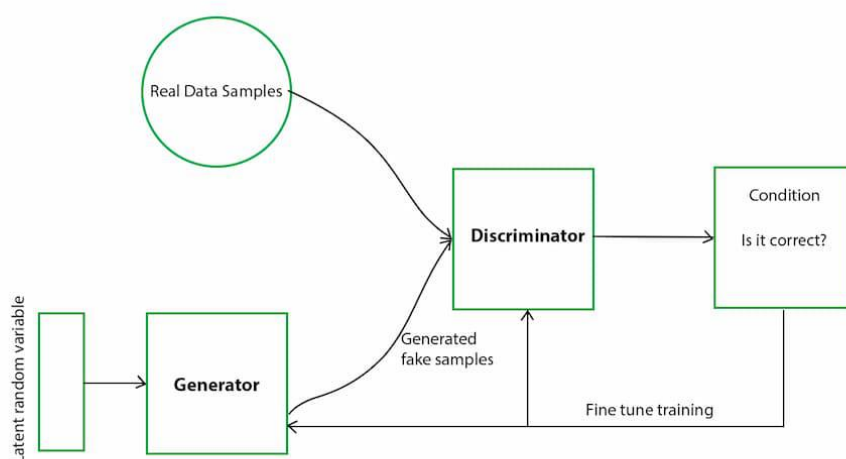
Zvýšená rýchlosť spracovania vďaka optimalizácii hardvéru: Integrácia čipov AI do technologického zásobníka je navrhnutá tak, aby zvýšila výpočtovú účinnosť lekárskeho zobrazovania, pretože optimálne vyladzuje hardvérovo akcelerované operácie hlbokého učenia. Tieto čipy teraz umožňujú paralelné spracovanie a efektívne výpočty, čím sa do veľkej miery skracuje čas potrebný na vykonávanie zložitých úloh, ako je napríklad analýza obrazu. Napríklad v prípade čipu AI so špecializovanými konvolučnými akcelerátormi môže byť spracovanie obrazu niekoľkonásobne rýchlejšie. [40]

Rozpoznávanie jemných diagnostických znakov: Tieto nové modely hlbokého učenia dokážu zachytiť jemné diagnostické znaky potrebné na odhalenie chorôb, ako je COVID-19, v počiatočných štádiách. Okrem toho viacškálové a multimodálne prístupy k učeniu zvyšujú citlivosť modelov voči jemnejším detailom, ktoré sú kriticky dôležité pre detekciu ochorení v ranom štádiu a drobných anomálií. Pokročilé modely typu DenseNet s konvolučnými modulmi pozornosti boli obzvlášť účinné pri riešení problému intenzívnej úrovne segmentácie mozgových nádorov, ktorá by bola užitočná na presnú analýzu zložitých lekárskeho snímkov [41]. Táto schopnosť je nevyhnutná pre včasnú a aktuálnu diagnostiku a následne môže zlepšiť výsledky pacientov prostredníctvom včasnej a cielenej liečby.

#### 2.4.4. Medzery a príležitosti pre výskum

Medicínske zobrazovanie je oblasť, v ktorej má príprava údajov pomocou rozšírených metód veľký vplyv na účinnosť modelov počas tréningu. Práca so zašumenými údajmi však zostáva doteraz najrozšírenejšou medzerou vo výskume. Na niektorých lekárskech snímkach môže dominovať šum, ktorý zatiení výrazné vzory potrebné na diagnostiku. Nevyvážené súbory údajov môžu viesť k skresleniu modelov a následne k slabému výkonu v nedostatočne zastúpených triedach. Ďalej boli vykonané komplexné štúdie na analýzu toho istého s integráciou rôznych pokročilých techník predspracovania a rozšírenia na systematickú analýzu ich vplyvu v rôznych architektúrach modelov. [42]

V tejto výskumnej oblasti existujú obrovské možnosti ďalšieho rozvoja. Inými slovami, kvalita tréningových súborov údajov a efektívnosť ich využitia by sa mohla výrazne zlepšiť inovatívnym zlepšením algoritmov redukcie šumu a vývojom nových spôsobov generovania syntetických údajov [42]. Pokročilé čistenie redukcie šumu by mohlo zlepšiť vstupné údaje na lepšie zvýraznenie podstatných vlastností a zlepšiť výsledky tréningu modelov. Niektoré zaujímavé metódy rozšírenia údajov, ako sú komplexné geometrické transformácie a fotometrické rozšírenia, v kombinácii s použitím generatívnych adverzných sietí (GAN) by mohli priniesť potrebnú variabilitu súborov údajov. Najmä GAN (Obr. 10) ponúka sľubné vyhliadky na generovanie syntetických lekárskeho obrazov, ktoré môžu simulovať širokú škálu patologických stavov, a teda riešiť problém nevyváženosti tried. [43]



Obrázok 10: GAN architektúra [44]

Takéto techniky rozšírenia pomôžu nielen pri obohacovaní súboru údajov, ale poskytnú aj robustnejší základ na tréovanie modelov hlbokého učenia, čím sa zlepši diagnostická presnosť a spoľahlivosť. To všetko spoločne prispieva k zlepšeniu predspracovania a rozšírenia údajov, ktoré sú nevyhnutné na zlepšenie schopností medicínskych zobrazovacích technológií. Všetky tieto medzery vo výskume je potrebné vhodne vyplniť, aby sa v oblasti lekárskeho zobrazovania úspešnejšie využívalo hlboké učenie v prospech pacientov prostredníctvom presnejšej a včasnejšej diagnostiky.

### 3. Ciele práce

Vo všeobecnosti je hlavným cieľom tejto práce využiť potenciál, ktorý ponúkajú neurónové siete, intenzívne sa učiace modely, pri klasifikácii röntgenových snímok, ktoré odrážajú anatomické štruktúry. Táto štúdia sa preto snaží riešiť niektoré významné problémy súvisiace s klasifikáciou röntgenových snímok, ako je nevyváženosť tried a vnútorné obmedzenia existujúce v súboroch údajov o röntgenových snímkach. Cieľom tohto výskumu je vyvinúť robustný diagnostický nástroj, konkrétne v oblasti zdravotníctva, ktorý môže výrazne zvýšiť presnosť a spoľahlivosť v týchto prostrediach. V nasledujúcich bodoch sú uvedené základné prístupy a metodiky:

#### Pokročilé techniky na zvýšenie výkonnosti modelu:

- *Zmierenie nerovnováhy tried:* Výskumné techniky, ako je rozšírenie údajov a váhy tried počas tréningu, na riešenie nevyváženosti tried, zníženie skreslenia v dominantných triedach a zvýšenie výkonu v menej zastúpených triedach.
- *Zlepšenie kvality údajov:* Zlepšenie konzistencie a kvality údajov prostredníctvom štandardizovaných krokov predspracovania, ako je zmena veľkosti a normalizácia obrázkov, čím sa zlepšia možnosti interpretácie a učenia modelov z obrázkov.

#### Testovanie a porovnávanie rôznych architektúr CNN:

- *Hodnotenie výkonnostných metrik:* Hodnotenie celkových výkonnostných ukazovateľov (Precision, Recall, F1-score) rôznych modelov CNN a získanie poznatkov na identifikáciu najvýkonnejších modelov na klasifikáciu röntgenových snímok.
- *Potenciál prenosu učenia:* Preskúmať možnosť použitia predtrénovaných modelov (napr. VGG, ResNet, atď.) ako extraktorov príznakov a posúdiť, ako ich možno jemne vyladiť pre lekárske zobrazovacie údaje.

#### Prispôsobenie modelov CNN na viacznačkovú (multilabel) klasifikáciu:

- *Modifikácie architektúry:* Úprava architektúr CNN na efektívne spracovanie viacerých labelov pomocou vhodných stratových funkcií, ako je binárna krížová entropia, a aktivačných funkcií, ako je sigmoid.
- *Stratégia jemného doladenia:* Doladovanie modelov pomocou techník hyperparametrov s cieľom maximalizovať výkonnosť, upravovať parametre, ako je rýchlosť učenia a veľkosť dávky, na základe charakteristík súboru údajov.

#### Implementácia a vyhodnotenie techník rozšírenia údajov:

- *Vplyv kategórií rozšírenia:* Testovanie vplyvu rôznych techník rozšírenia (geometrické transformácie, úpravy farieb, pridávanie šumu) na schopnosť modelov zovšeobecniť sa a robustne fungovať v rôznych podmienkach zobrazovania.
- *Zovšeobecňujúca schopnosť a efektívnosť vzorkovania:* Zamerať sa na to, ako môžu techniky rozšírenia pomôcť znížiť nadmerné prispôbovanie a zvýšiť výkonnosť, najmä pri učení zo súborov údajov s nízkym počtom značiek.

Očakáva sa, že výsledky tejto práce budú cenným prínosom pre oblasť lekárskeho diagnostických nástrojov ako zdokonalený nástroj analýzy röntgenových snímok a prípadne povedú aj k vývoju spoľahlivejších a presnejších diagnostických systémov v zdravotníckych zariadeniach.



## 4. Metodológia

### 4.1. Relevantnosť súboru údajov a teoretická relevantnosť

Kvalita súboru údajov významne ovplyvňuje účinnosť modelov hlbokého učenia v lekárskom zobrazovaní. Na účely tohto výskumu bol dátový súbor obsahujúci anotované röntgenové snímky rôznych častí tela získaný zo stránky Kaggle [45]. Tento súbor údajov zahŕňa kľúčové aspekty, ako je rozlíšenie snímok, rozmanitosť zastúpených častí tela a jasnosť, s akou sú tieto anatomické štruktúry zobrazené, pričom každý z nich zohráva kľúčovú úlohu pri trénovaní a výkonnosti modelov.

Obrázky s vysokým rozlíšením sú nevyhnutné pre lekársku diagnostiku, pretože umožňujú modelu rozoznať presné znaky potrebné na odhalenie jemných patologických príznakov. Vysoká dimenzionalita súborov údajov s vysokým rozlíšením však môže zvýšiť výpočtové nároky a riziko nadmerného prispôsobenia. Súbor údajov v tejto štúdii obsahuje obrázky (Obr. 11) z 22 rôznych tried, ktoré predstavujú širokú rozmanitosť lekárskeho stavov. Táto variabilita je nielen výzvou pre model, ale zároveň zvyšuje jeho robustnosť. Prítomnosť 1 738 anotovaných obrázkov poskytuje nemalý objem údajov, ktoré sú kľúčové pre trénovanie sofistikovaných modelov hlbokého učenia schopných komplexných úloh rozpoznávania vzorov a rozhodovania. Vo všeobecnosti platí, že väčší súbor údajov sa premieta do lepšej výkonnosti modelu, najmä v kritických oblastiach, ako je lekárska diagnostika.



Obrázok 11 Ukážka tried röntgenových snímok z použitého súboru údajov: 1- Lebka (Trieda 18), 2- Ruka (Trieda 9), 3- Chodidlo (Trieda 6), 4- Koleno (Trieda 11)  
zdroj: autor

Vlastnosti súboru údajov priamo ovplyvňujú robustnosť modelu, ktorá je definovaná ako schopnosť modelu udržať si vysoký výkon na nových, nepozorovaných údajoch. Rozmanitosť a objem súboru údajov sú nápomocné pri zmierňovaní bežných problémov, ako je nadmerné prispôsobovanie. Okrem toho rôznorodosť podmienok a vysokokvalitných obrázkov v rámci súboru údajov umožňuje modelom hlbokého učenia efektívne učiť sa jemné vlastnosti lekárskeho obrázkov. Toto učenie je nevyhnutné na vývoj modelov, ktoré sú presné, spoľahlivé a účinné pri diagnostických predpovediach.

Bohatosť súboru údajov poskytuje dostatok príležitostí na pokročilé tréningovanie modelov, ale zároveň predstavuje aj výzvy, ako napríklad významné predbežné spracovanie potrebné na štandardizáciu obrázkov pre konzistentný vstup do modelu. Okrem toho si rozmanitá povaha súboru údajov vyžaduje sofistikované stratégie rozširovania údajov na simuláciu variability reálneho sveta, čím sa zvyšuje schopnosť modelu fungovať v rôznych podmienkach.

## 4.2. Príprava a predbežné spracovanie údajov

Účinné predspracovanie je kľúčové pre prípravu medicínskych obrazových údajov pre modely hlbokého učenia.

Zmena veľkosti obrázkov je nevyhnutná na zabezpečenie konzistentnej veľkosti obrázkov v celom súbore údajov, čo umožní neurónovej sieti efektívne spracovať údaje. Obrázky sa zvyčajne zmenšujú na štandardné rozmery, v tomto prípade napríklad  $224 \times 224$  alebo  $299 \times 299$  pixelov. Táto štandardizácia zjednodušuje výpočtové procesy tým, že znižuje variabilitu štruktúry vstupných údajov a zabezpečuje jednotnú veľkosť vstupných údajov pre model. Takáto jednotnosť je veľmi dôležitá, pretože pomáha neurónovej sieti pri učení a efektívnej extrakcii funkcií bez dodatočnej zložitosti vyplývajúcej z rôznych veľkostí obrázkov.

Normalizácia hodnôt pixelov na spoločnú stupnicu, buď od 0 do 1, alebo od -1 do 1, je ďalším kľúčovým krokom. Toto škálovanie stabilizuje výkon modelov hlbokého učenia tým, že im pomáha rýchlejšie konvergovať počas tréningu a znižuje citlivosť na rozsah vstupných hodnôt. Normalizácia uľahčuje konzistentnejšiu mieru učenia rôznych funkcií, čím sa zvyšuje celková účinnosť a efektívnosť tréningu modelu.

Konverzia do odtieňov sivej je obzvlášť dôležitá v mnohých typoch lekárskeho zobrazovania, kde farba neprináša pridanú diagnostickú hodnotu. Konverzia obrazov do odtieňov sivej znižuje výpočtové nároky znížením dimenzionality údajov. To umožňuje modelu zamerať sa viac na štrukturálne rozdiely než na farebné rozdiely, čo je mimoriadne dôležité pri úlohách, ako je analýza röntgenových snímok a magnetickej rezonancie, kde sú štrukturálne detaily významnejšie než farba.

Tieto stratégie predbežného spracovania spoločne riešia potrebu štandardizácie aj výzvy, ktoré predstavuje prirodzená variabilita a zložitosť lekárskeho obrazových údajov. Sú navrhnuté tak, aby dôkladne pripravili údaje a zabezpečili, že modely hlbokého učenia budú tréňované na údajoch, ktoré sú čo najkonzistentnejšie a najinformatívnejšie.

### 4.3. Stratégie rozšírenia údajov

Táto kapitola sa zaoberá významom rozšírenia údajov v strojovom učení, najmä v oblasti lekárskeho zobrazovania. Vysvetľuje, ako rôzne techniky rozšírenia údajov, ako sú geometrické transformácie, úpravy farieb a zavedenie šumu, podstatne zlepšujú robustnosť a zovšeobecnenie modelu. Umelým rozšírením trénovacej množiny údajov tieto metódy pomáhajú predchádzať nadmernému prispôbovaniu a zabezpečujú, aby modely dokázali efektívne zvládnuť širokú škálu scenárov z reálneho sveta.

#### 4.3.1. Zdôvodnenie augmentácie

Rozšírenie údajov je nevyhnutné v strojovom učení, najmä v lekárskom zobrazovaní, kde variabilita údajov a veľkosť súboru údajov významne ovplyvňujú výkonnosť modelu. Umelým rozšírením súboru údajov prostredníctvom rôznych transformácií sa zvyšuje robustnosť a zovšeobecniteľnosť modelu. Tento proces nielenže znižuje riziko nadmerného prispôsobenia, ale tiež zabezpečuje, že model dokáže efektívne spracovať širokú škálu scenárov z reálneho sveta. Používané typy rozšírenia sa môžu značne líšiť, pričom každý z nich slúži na špecifický účel pri zlepšovaní učenia modelu:

*Geometrické transformácie:* Patria sem rotácie, otočenia, škálovanie a translácie. Takéto transformácie sú obzvlášť cenné pri lekárskom zobrazovaní, kde sa poloha objektov môže výrazne líšiť. Tým, že geometrické transformácie umožňujú modelu rozpoznávať prvky na snímkach bez ohľadu na ich orientáciu a mierku, pomáhajú zabezpečiť, aby diagnostická presnosť nebola ohrozená fyzickou prezentáciou snímky.

*Úpravy farieb:* Hoci sa v lekárskom zobrazovaní neuplatňujú vždy, úpravy farieb zohrávajú kľúčovú úlohu v špecifických oblastiach, ako sú dermatologické snímky alebo farebné skeny. Úpravy, ako je jas, kontrast a vyrovnanie histogramu, môžu mať zásadný význam pre zvýšenie jasnosti obrazu, čo modelu uľahčí detekciu relevantných prvkov na snímkach.

*Zavedenie šumu:* Pridanie syntetického šumu, ako je Gaussov šum alebo šum typu sol' a peper, simuluje bežné artefakty, ktoré sa môžu vyskytovať v lekárskejších snímkach. Tento typ rozšírenia trénuje model, aby sa zameral na relevantné prvky napriek prítomnosti šumu, čím sa zvyšuje jeho diagnostická presnosť v menej ideálnych podmienkach.

Rozšírenie údajov sa ukazuje ako obzvlášť prospešné, keď súbor údajov ako celok alebo špecifické triedy v ňom majú obmedzené vzorky. Zvýšením efektívnej veľkosti trénovaného súboru údajov prostredníctvom týchto techník rozšírenia sa model učí zo širšieho a rozmanitejšieho súboru prezentovaných údajov. Tým sa znižuje tendencia modelu zapamätať si trénované údaje a zvyšuje sa jeho schopnosť zovšeobecňovať na nové, nepozorované údaje.

#### **4.3.2. Stratégie rozširovania údajov a ich vplyv na výkonnosť modelov**

Rozšírenie údajov zohráva kľúčovú úlohu pri zlepšovaní schopnosti učenia a rozpoznávania modelov v lekárskom zobrazovaní. Tréningom s rozšírenými údajmi získavajú modely lepšie schopnosti zovšeobecňovania, vďaka čomu je menej pravdepodobné, že sa budú nadmerne prispôsobovať nuansám trénovacej množiny, a je pravdepodobnejšie, že budú presne fungovať v nových, neznámych súboroch údajov. To je obzvlášť dôležité v lekárskejších aplikáciách, kde je nevyhnutný konzistentný výkon v rôznych klinických prostrediach. Okrem toho rozšírenie zavádza variabilitu, ktorá trénuje model, aby ignoroval irelevantné odchýlky vo vstupných údajoch, ako je šum alebo neštandardizovaná orientácia obrazu, čím sa zvyšuje robustnosť modelu. Takáto robustnosť je kľúčová pre klinické nasadenie, kde sa obrazy nemusia vždy prezentovať za ideálnych podmienok.

##### Konkrétne príklady a výhody:

*Rotácia a otočenie:* Tieto rozšírenia pomáhajú modelu naučiť sa rozpoznávať anatomicke štruktúry z rôznych uhlov, čím sa zvyšuje presnosť a flexibilita modelu pri klinickej diagnostike.

*Šum:* Zavedenie šumu počas tréningu pripraví model na efektívnejšie spracovanie nekvalitných klinických snímok, čím sa zabezpečí spoľahlivosť aj za neoptimálnych podmienok.

Pri výbere konkrétnych techník rozšírenia sa výber často odôvodňuje na základe ich preukázanej účinnosti v predchádzajúcich štúdiách a ich relevantnosti pre typy lekárskeho zobrazovacích údajov používaných vo výskume. Napríklad:

*Geometrické a šumové rozšírenia:* Tieto sa vyberajú pre ich schopnosť simulovať skutočné rozdiely v lekárskej zobrazovanej, ako je pohyb pacienta alebo rozdiely v zobrazovacej technológii. Tieto typy rozšírení pomáhajú zabezpečiť, aby model zvládol širokú škálu zobrazovacích podmienok.

*Úpravy farieb:* Tieto sa vyberajú predovšetkým pre súbory údajov zahŕňajúce obrazy vo viditeľnom svetle, kde informácie o farbe môžu poskytnúť významnú diagnostickú hodnotu. Úpravy, ako je jas, kontrast a vyrovnanie histogramu, sú obzvlášť cenné pri zlepšovaní zistiteľnosti jemných znakov na snímkach.

Tieto rozširujúce stratégie spoločne nielenže pripravujú modely na zvládnutie rôznych obrazových podmienok, ale tiež významne prispievajú k celkovej účinnosti a spoľahlivosti lekárskej diagnostiky v reálnych aplikáciách.

#### **4.4. Výber modelu**

Výber vhodných modelov hlbokého učenia pre lekárske zobrazovanie je kľúčovým rozhodnutím, ktoré priamo ovplyvňuje účinnosť, efektivitu a praktickú použiteľnosť diagnostického nástroja. Vybrané modely musia vynikať architektonickými schopnosťami, výpočtovou efektívnosťou a musia mať overené výsledky v podobných aplikáciách.

Modely sa vyberajú predovšetkým podľa ich schopnosti efektívne spracovať komplexné obrazové údaje, pričom sa kladie dôraz na vlastnosti, ako je hĺbka architektúry a špecializované vrstvy, napríklad konvolučné vrstvy, ktoré sú kľúčové pre extrakciu detailných vlastností potrebných na presnú diagnostiku. Modely musia tiež vykazovať vysokú výpočtovú účinnosť, aby sa zabezpečilo rýchle spracovanie v klinických prostrediach, kde je rozhodujúce rýchle rozhodovanie.

Kľúčové použité modely:

- *224x224 Optimálna veľkosť:*

- VGG-19: Vyznačuje sa hlbokou architektúrou, ktorá je účinná pri podrobnej extrakcii funkcií.
- Varianty siete ResNet (ResNet-50, ResNet-101, ResNet-152): Obsahujú zvyškové učenie na podporu hlbšieho tréningu siete, ktoré je nevyhnutné na komplexnú analýzu obrazu.
- Varianty siete DenseNet (DenseNet-121, DenseNet-169, DenseNet-201): Využívajú husto pripojené vrstvy na efektívne využívanie parametrov a robustný prenos funkcií, čím optimalizujú výpočtové zdroje.
- Varianty EfficientNet (EfficientNet-B0, EfficientNet-B1, EfficientNet-B2): Systematicky škálované na efektívne spracovanie rôznych rozlíšení obrazu.

- *Optimálna veľkosť  $299 \times 299$ :*

- InceptionResNetV2: Zlučuje architektúru Inception so zvyškovými pripojeniami, čím vyvažuje pokročilé možnosti učenia s výpočtovou efektívnosťou, ideálne pre obrazy s vyšším rozlíšením.
- InceptionV3: Je známy svojou prevádzkovou účinnosťou a presnosťou pri vyšších rozlíšeníach, využíva sofistikované konvolúcie a stratégie redukcie rozmerov na optimalizáciu výpočtových nárokov.

Tieto modely boli starostlivo vybrané s cieľom zvýšiť presnosť a efektívnosť analýzy medicínskych obrazov, pričom sa opierali o svoje osvedčené schopnosti spracúvať zložité obrazové údaje a inovatívne architektonické prvky, ktoré zabezpečujú prispôsobivosť a robustnosť v rôznych scenároch medicínskeho zobrazovania.

## **4.5. Rámec hodnotenia**

V tejto kapitole sa uvádza dôležitosť výberu vhodných hodnotiacich ukazovateľov, ako sú presnosť, precíznosť, spätná väzba a skóre F1, ktoré sú rozhodujúce na meranie výkonnosti a zabezpečenie klinickej spoľahlivosti modelov lekárskeho zobrazovania. Opisuje sa v nej aj štruktúrovaná testovacia stratégia, ktorá rozdeľuje údaje na tréningovú, validačnú a testovaciu sadu, čo umožňuje dôkladné ladenie modelu a validáciu s cieľom posúdiť, ako dobre model funguje v reálnych diagnostických scenároch.

### **4.5.1. Hodnotiace parametre**

Výber vhodných hodnotiacich ukazovateľov je rozhodujúci pre presný odhad výkonnosti vyvinutých metód v lekárskom zobrazovaní, čím sa zabezpečí, že spĺňajú klinické normy pre presnosť a reprodukovateľnosť. Presné metriky usmerňujú zlepšovanie modelov počas celého procesu vzdelávania a sú nevyhnutné pre klinickú validáciu.

Presnosť meria celkový počet správnych predpovedí vykonaných modelom vo všetkých triedach, čo je nevyhnutné na monitorovanie a zlepšovanie krivky učenia modelu počas jeho vývoja. Precíznosť alebo pozitívna prediktívna hodnota udáva podiel správnych pozitívnych identifikácií vykonaných modelom, čo je rozhodujúce v lekárskejších podmienkach, kde sú náklady na falošne pozitívne výsledky vysoké. Spätná väzba (Recall), známa aj ako citlivosť, hodnotí schopnosť modelu zachytiť všetky relevantné prípady stavu, čím sa zabezpečí, že pri diagnostike sa nevynechajú žiadne kritické informácie. Skóre F1, harmonický priemer precíznosti a spätnej väzby, ponúka vyváženú mieru precíznosti a robustnosti modelu, čo je užitočné najmä v podmienkach s nevyváženými súbormi údajov.

Tieto metriky spoločne poskytujú komplexný rámec na posúdenie výkonnosti modelu, pričom podrobne opisujú výsledky pre každú triedu počas testovania a ponúkajú pohľad na schopnosť modelu efektívne zvládnuť rôzne zdravotné stavy.

#### **4.5.2. Rozdelenie súboru údajov**

Na zabezpečenie spoľahlivého procesu hodnotenia, ktorý odráža reálne scenáre lekárskej diagnostiky, sú súbory údajov strategicky rozdelené do troch kľúčových sekcií.

Trénovacia množina sa používa na počiatočné ladenie parametrov modelu - nastavenie váh a odchýlok počas niekoľkých iterácií s cieľom minimalizovať stratovú funkciu. Táto množina tvorí najväčšiu podmnožinu a poskytuje modelu podstatnú základňu na učenie sa rôznych vzorov a funkcií nevyhnutných na presnú diagnostiku.

Validačná množina zohráva kľúčovú úlohu pri ladení hyperparametrov modelu a implementácii mechanizmov včasného zastavenia, aby sa zabránilo nadmernému prispôbaniu. Funguje ako dôležitý kontrolný bod, ktorý umožňuje zdokonaľovanie modelu v kontrolovanom prostredí, ktoré zabraňuje úniku informácií o testovacích údajoch. To pomáha zabezpečiť, aby sa zlepšenia dali zovšeobecniť a neboli optimalizované len pre trénované údaje.

Nakoniec, testovacia množina slúži ako definitívne kritérium na posúdenie toho, ako bude model fungovať v praktických scenároch. Využíva sa až po úplnom natrénovaní a overení modelu. Táto množina, ktorá obsahuje nové, neoverené údaje, je rozhodujúca pre konečné hodnotenie schopností modelu. Výkonnosť modelu sa hodnotí pomocou precíznosti, spätnej väzby a skóre F1 pre každú triedu, čo ponúka komplexný pohľad na jeho diagnostické schopnosti v rôznych zdravotných stavoch.



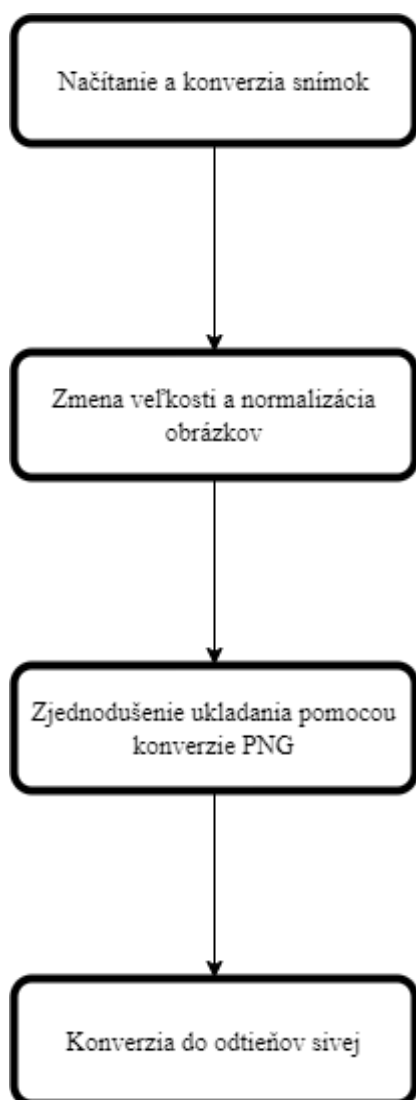
## **5. Implementácia**

### **5.1. Vykonávanie prípravy a rozširovania údajov**

V tejto kapitole sa rozoberajú základné kroky súvisiace s prípravou lekárskeho obrazových údajov na efektívne tréning modelov strojového učenia, ktoré zahŕňajú konverziu, zmenu veľkosti a normalizáciu obrázkov na zabezpečenie jednotnosti. Zahŕňa aj implementáciu rôznych techník rozšírenia údajov na zvýšenie robustnosti a zovšeobecnenia modelu. Tieto procesy zahŕňajú geometrické transformácie, úpravy šumu a rozmazania a úpravy farieb, čím sa zabezpečuje, aby modely mohli presne interpretovať lekárske snímky v rôznych podmienkach, ktoré sa vyskytujú v reálnom svete.

#### **5.1.1. Implementácia predbežného spracovania**

Správna príprava medicínskych zobrazovacích údajov je nevyhnutná na nácvik presných diagnostických modelov. To zahŕňa niekoľko kľúčových krokov na štandardizáciu snímok a zabezpečenie ich podoby, z ktorej sa počítačové modely môžu efektívne učiť.



Obrázok 12 Kroky predspracovania  
zdroj: autor

Lekárske obrázky sa pôvodne načítavajú z formátu DICOM, ktorý obsahuje rozsiahle metadáta. Extrahovaním iba obrazových údajov sa odstránia nepotrebné detaily, aby sa modely zamerali na vizuálne vzory. Tieto obrázky sa potom konvertujú do ľahšie ovládateľného formátu PNG.

Každý obrázok sa zmenší na štandardnú veľkosť (napr.  $224 \times 224$  alebo  $299 \times 299$  pixelov), ktorá je potrebná pre konzistentnosť modelov strojového učenia. Normalizácia sa používa na zabezpečenie jednotného jas a kontrastu, čo pomáha modelom pri rozpoznávaní štruktúrnych rozdielov, a nie rozdielov v osvetlení.

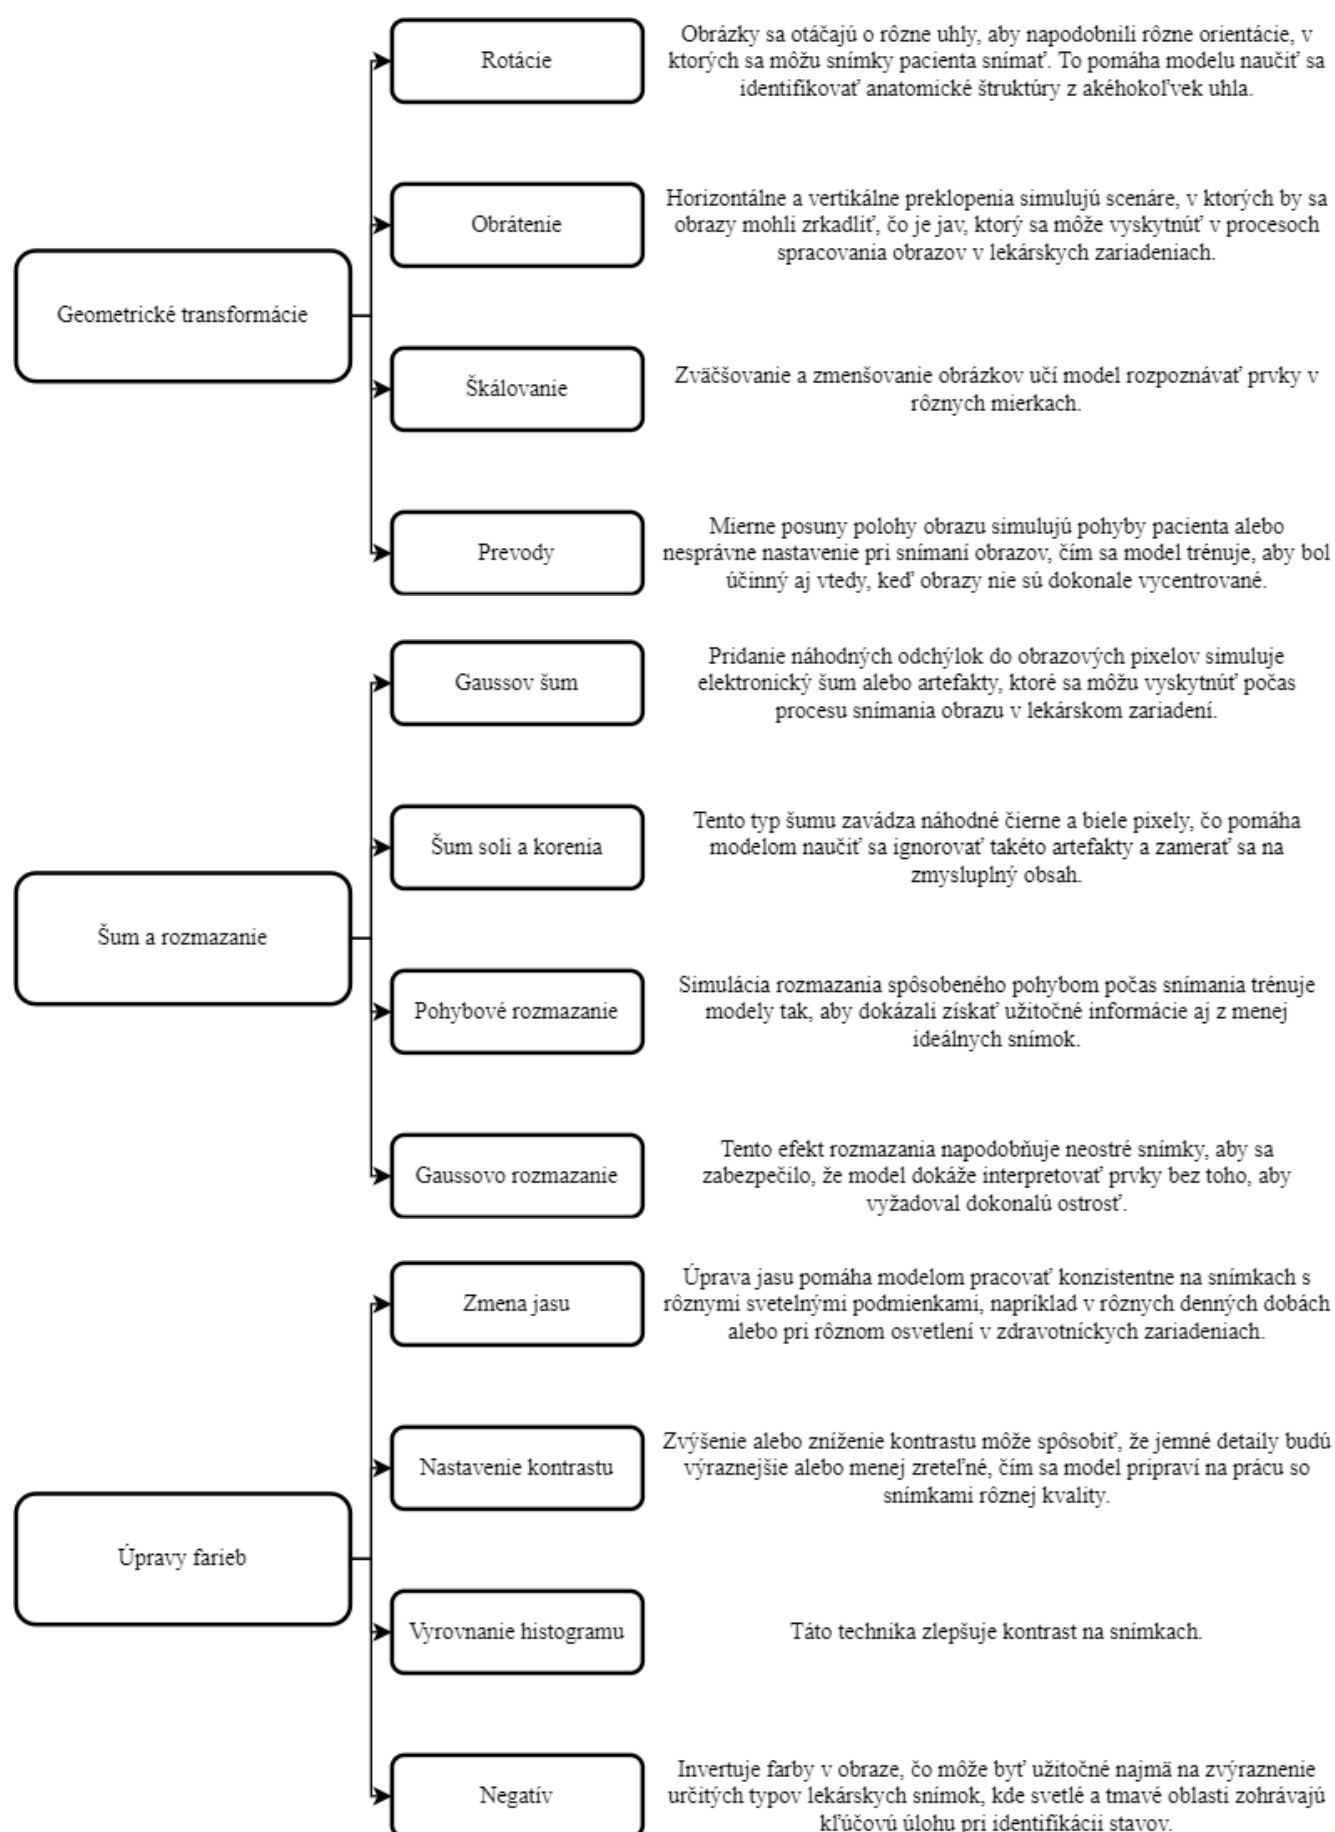
Po konverzii do formátu PNG sa obrázky usporiadajú do jednoduchšieho systému priečinkov. Táto organizácia zjednodušuje proces vyhľadávania počas tréningu modelov, čím sa zvyšuje efektívnosť.

V prípadoch, keď sú farebné informácie zbytočné, ako napríklad röntgenové snímky alebo snímky MRI, sa obrázky konvertujú do odtieňov sivej. Tým sa znižuje zložitosť údajov a veľkosť súborov, urýchľuje sa proces tréningu a model sa zameriava na štruktúrne informácie.

Tieto kroky predspracovania (Obr. 12) automatizuje vlastný softvérový skript. Pomocou tohto skriptu je zabezpečené, aby sa s každým obrázkom v súbore údajov zaobchádzalo rovnakým spôsobom, čo je rozhodujúce pre spoľahlivosť modelov. Táto konzistentnosť pomáha eliminovať potenciálne skreslenia alebo chyby, ktoré by mohli vzniknúť pri ručnom spracovaní väčšieho súboru údajov.

### 5.1.2. Použité techniky augmentácie

Rozšírenie údajov je technika, ktorá sa používa na vytvorenie rozmanitejšieho súboru údajov umelou úpravou obrázkov. Tento proces pomáha modelom naučiť sa interpretovať lekárske snímky za rôznych podmienok, s ktorými sa môžu stretnúť v reálnom prostredí.



Obrázok 13 Techniky rozšírenia údajov zdroj: autor

Boli použité tri rôzne kategórie techník rozširovania údajov (Obr. 13)

Proces rozšírenia využíva robustný skript, ktorý tieto transformácie náhodne aplikuje na obrázky v súbore údajov. Táto náhodnosť zabezpečuje, že model sa príliš neprispôsobí špecifickým atribútom trénovacej množiny a môže sa dobre zovšeobecniť na nové, nevidené obrázky. Skript systematicky ukladá každý rozšírený obrázok s jedinečným identifikátorom, čím udržiava organizovaný a sledovateľný súbor údajov, ktorý zabezpečuje reprodukovateľnosť a systematické hodnotenie.

## **5.2. Spracovanie a delenie súborov údajov**

V tejto kapitole sú uvedené záverečné prípravy potrebné na zabezpečenie toho, aby bol súbor údajov pripravený na tréovanie modelu, vrátane dôkladných kontrol a používania súborov CSV na efektívnu správu údajov. Vysvetľuje sa v nej rozdelenie súboru údajov na trénovaciu, validačnú a testovaciu sadu s použitím prispôsobeného prístupu na riešenie jedinečných obmedzení, ako je obmedzená dostupnosť obrázkov pre určité triedy. Na zabezpečenie vyváženého rozdelenia vo všetkých segmentoch súboru údajov sa používa stratifikované vzorkovanie, čím sa zvyšuje výkonnosť modelu a spravodlivosť pri školení.

### **5.2.1. Praktický prehľad a nastavenie súboru údajov**

Po predbežnom spracovaní a rozšírení je nevyhnutné vykonať záverečné prípravy, aby bol súbor údajov plne pripravený na experimenty, čo je rozhodujúce pre uľahčenie bezproblémového tréovania modelu. Táto fáza zahŕňa záverečné kontroly a nastavenie súboru údajov.

Najprv sa vykonajú záverečné kontroly a konfigurácia. Všetky snímky, teraz už predspracované a rozšírené, sa starostlivo skontrolujú, aby sa zabezpečilo, že spĺňajú požadované normy kvality a formátu na tréovanie. To zahŕňa overenie, či sú rozlíšenia a formáty obrázkov konzistentné a správne zosúladené so vstupnými špecifikáciami modelu.

Ďalej pri efektívnom spracovaní súboru údajov zohráva kľúčovú úlohu správa súborov CSV. Súbory CSV sa využívajú na katalogizáciu podrobností, ako sú cesty k obrázkom a ich príslušné označenia. Tento systém uľahčuje systematický prístup k súboru údajov a manipuláciu s ním počas celého procesu školenia. Použitie súborov CSV zabezpečuje, že každý obrázok je presne označený a ľahko vyhľadateľný, čo výrazne zefektívňuje tréningový pracovný postup.

### 5.2.2. Proces rozdelenia

Na efektívne tréningovanie a overovanie modelov je nevyhnutné rozdeliť súbor údajov na tréningovú, overovaciu a testovaciu množinu. Toto štruktúrované rozdelenie je rozhodujúce pre vyhodnocovanie modelov v kontrolovaných a nezaujatých podmienkach. Vzhľadom na jedinečné obmedzenia tohto súboru údajov, ako je napríklad obmedzená dostupnosť obrázkov pre určité triedy, bežné rozdelenie na 80 % tréningovanie, 10 % validáciu a 10 % testovanie nie je vhodné. Namiesto toho sa na zabezpečenie spravodlivosti a efektívnosti tréningu používa prispôbený prístup:

Rozdelenie súboru údajov zahŕňa pridelenie určitého počtu vzoriek pre každú triedu do testovacích a validačných súborov, čím sa zabezpečí, že aj nedostatočne zastúpené triedy budú primerane vyhodnotené a zmysluplne prispedia k procesu učenia modelu. Hoci sa nepoužíva štandardné percentuálne rozdelenie, väčšina údajov je stále určená pre tréningovú množinu, aby poskytla spoľahlivý základ pre učenie. To je rozhodujúce pre rozvoj silných predikčných schopností.

Na dosiahnutie vyváženého rozdelenia sa používa stratifikované vzorkovanie, aby sa zabezpečilo, že každá množina - tréningová, validačná a testovacia - obsahuje reprezentatívny podiel každej triedy. Táto metóda je mimoriadne dôležitá pri spracovaní nevyvážených súborov údajov, pretože zabraňuje tomu, aby sa v modeli vyvinula zaujatosť voči častejšie zastúpeným triedam.

Na presné priradenie obrázkov do každého segmentu súboru údajov podľa konkrétnych čísel definovaných pre každú triedu sa využívajú automatizované skripty.

## 5.3. Modelový tréningový proces

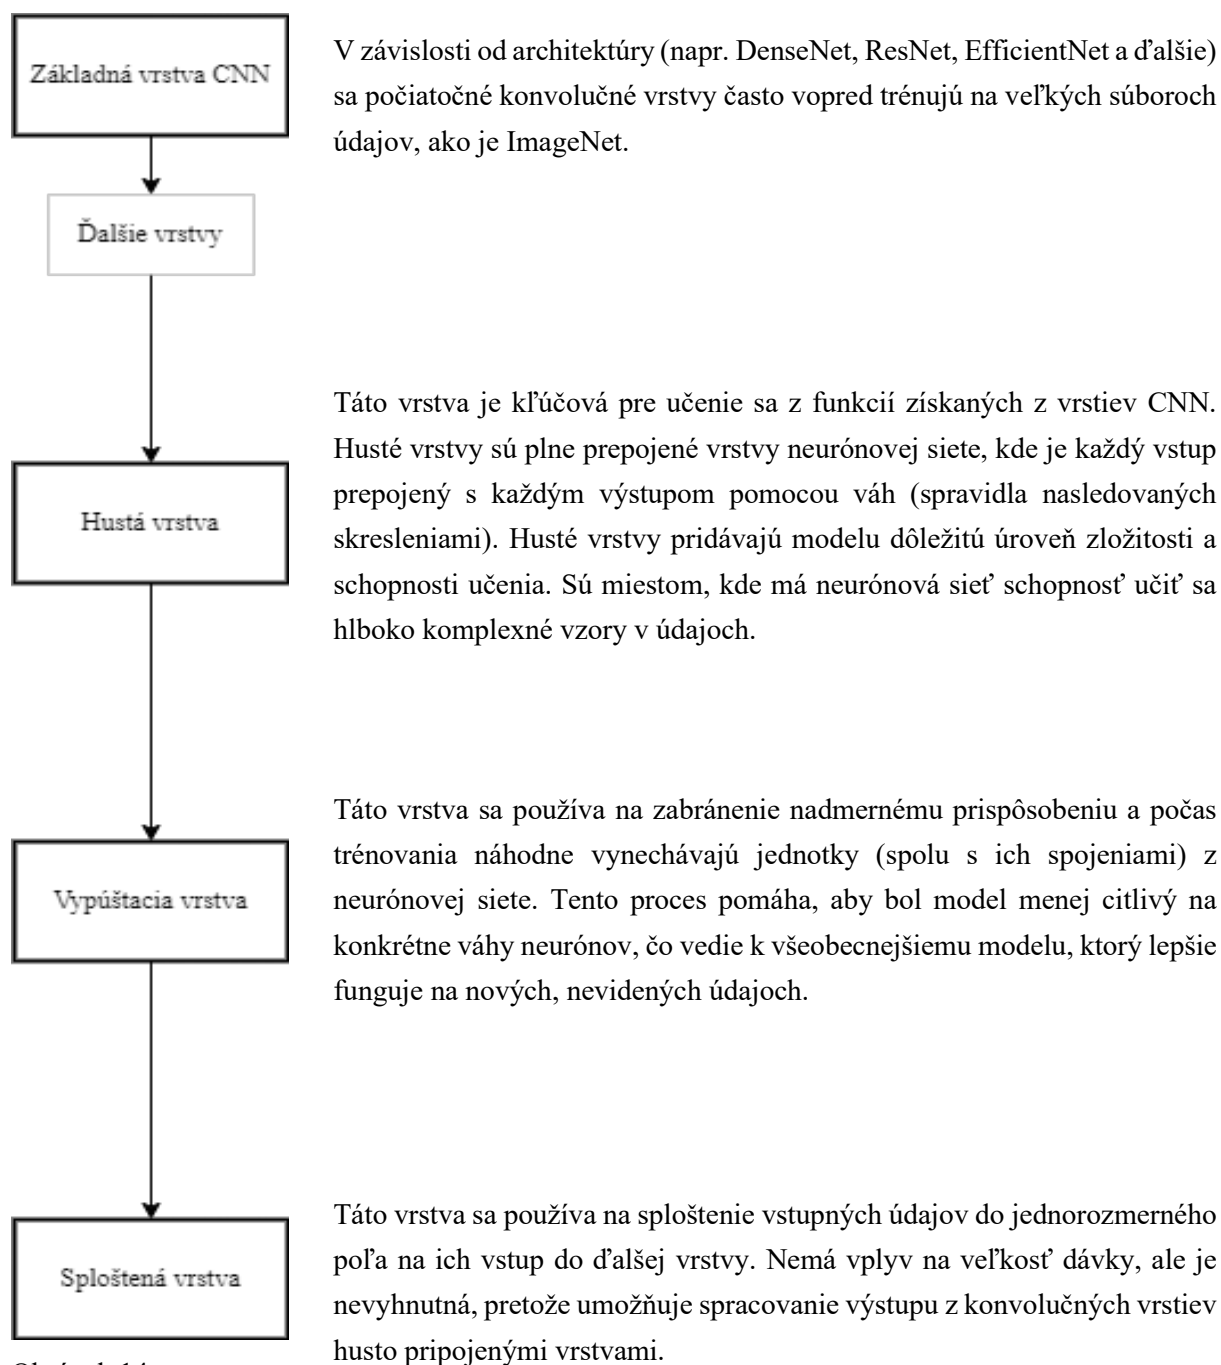
Táto kapitola opisuje nastavenie a vykonávanie tréningovania modelov pre aplikácie lekárskeho zobrazovania s využitím robustného hardvéru a rámcov hlbokého učenia, ako sú TensorFlow a Keras, na efektívne zvládnutie výpočtovo náročných úloh. Podrobne opisuje rôzne architektúry CNN a stratégie tréningovania vrátane používania vopred natrénovaných vrstiev a techník, ako je zmrazenie vrstiev a ich vynechanie, na zlepšenie generalizácie a zníženie nadmerného prispôbovania.

### **5.3.1. Nastavenie tréningového prostredia**

Pri tréningu sa využíva výkonný hardvér vrátane grafického procesora Nvidia GeForce RTX 3060 Laptop a procesora Intel i7 umiestneného v počítači ASUS TUF Dash F15 (2022). Táto zostava zabezpečuje efektívne zvládanie výpočtovo náročných úloh spojených s hlbokým učením. TensorFlow a Keras sú použité vďaka ich rozsiahlej podpore pre aplikácie hlbokého učenia, ktoré poskytujú flexibilné a výkonné nástroje na vývoj modelov.

### **5.3.2. Vykonávanie tréningu modelu**

Používajú sa rôzne architektúry CNN upravené pre viacnásobnú klasifikáciu a doplnené viacerými vrstvami (Obr. 14) na základe ich overených schopností v úlohách rozpoznávania obrazu.



Obrázok 14  
Architektúra vrstiev  
CNN modelu zdroj: autor

Počiatočné vrstvy každého predtrénovaného modelu sú zmrazené, aby sa zachovali všeobecné vlastnosti, ktoré sa tieto vrstvy naučili z rozsiahleho predtrénovania. Tieto vlastnosti sú široko použiteľné v rôznych obrazoch a úlohách, čím poskytujú silný a relevantný základ, ktorý si nevyžaduje preškolenie. Zmrazenie týchto vrstiev urýchľuje proces tréningu, pretože sa aktualizujú len vrchné vrstvy, čo výrazne znižuje výpočtovú náročnosť. Táto stratégia tiež zlepšuje schopnosť modelu zovšeobecňovať, pretože zabráňuje nadmernému prispôbovaniu modelu nuansám nového súboru údajov.

Trénovanie sa vykonáva počas viacerých epoch s použitím tréningových aj validačných súborov údajov. Tento prístup umožňuje priebežné monitorovanie a úpravu na základe výkonu modelu na validačných údajoch, čo je rozhodujúce pre ladenie modelu na dosiahnutie najlepších výsledkov.

### **5.3.3. Zvládanie výziev pri trénovaní**

Efektívna správa výpočtových zdrojov je vzhľadom na intenzívnu povahu trénovania hlbokých neurónových sietí kľúčová. Stratégie ako dávkové spracovanie a správa pamäte sú optimalizované tak, aby sa maximalizovala priepustnosť a efektívnosť trénovania. V konkrétnych experimentoch sa počítajú váhy tried a používajú sa na riešenie nerovnováhy v zastúpení tried. Táto úprava pomáha zabezpečiť, aby model nebol zaujatý voči prevažujúcim triedam. Tréning sa priebežne monitoruje z hľadiska výkonnostných ukazovateľov, ako je presnosť a strata, čo umožňuje úpravy v reálnom čase na optimalizáciu výkonu modelu. Grafická vizualizácia výsledkov trénovania a validácie pomáha pri posudzovaní výkonnosti modelu a identifikácii trendov, ako je nadmerné alebo nedostatočné prispôsobenie.

## **5.4. Príprava na hodnotenie výkonnosti**

V tejto kapitole sa podrobne opisuje proces hodnotenia medicínskych diagnostických modelov po ukončení školenia, pričom sa kladie dôraz na zachovanie a presné posúdenie konfigurácií modelov prostredníctvom systematických techník ukladania a opätovného načítania. Výkonnosť sa prísne hodnotí pomocou kľúčových metrík, ktoré uľahčujú podrobné klasifikačné správy a vizuálne reprezentácie údajov. Toto komplexné hodnotenie zabezpečuje presné testovanie modelov za konzistentných podmienok, čím sa zvýrazňuje ich potenciál na efektívne nasadenie v lekárskej diagnostike.

### **5.4.1. Testovanie a hodnotenie modelov**

Po ukončení dôkladnej tréningovej fázy sa modely okamžite podrobia hodnoteniu výkonnosti pomocou pripraveného súboru testovacích údajov. Toto hodnotenie je kľúčové pre posúdenie schopnosti modelov účinne zovšeobecňovať nové, nepozorované údaje - kľúčový faktor pre ich potenciálne nasadenie v lekárskej diagnostike.



Proces hodnotenia sa začína uložením každého modelu spolu s príslušným MultiLabelBinarizerom (MLB). Tento postup zabezpečuje, že všetky klasifikačné značky sú zachované a modely sa dajú spoľahlivo obnoviť s ich naučenými konfiguráciami na presné hodnotenie. Modely sa ukladajú pomocou formátu *model.save('path\_to\_model.h5')*, ktorý zabezpečuje naučené váhy a architektúru. MLB sa ukladá pomocou *joblib.dump(mlb, 'path\_to\_mlb.pkl')*, čo je krok rozhodujúci pre zachovanie konzistentnosti kódovania labelov medzi fázami tréningu a testovania, čím sa zabezpečí správna interpretácia labelov počas vyhodnotení.

Pri testovaní sa modely znovu načítajú z ich uložených stavov, aby sa zaručilo, že vyhodnotenie presne odráža ich podmienenú výkonnosť po tréningu. Modely sa načítajú zo svojich súborov *.h5*, ktoré obsahujú celú architektúru modelu spolu s natrénovanými váhami, pričom sa opätovne načíta aj uložený MLB, čo uľahčuje správnu interpretáciu labelov počas testovania.

Okrem toho sa testovacie údaje spracúvajú rovnakými metódami ako tréňované údaje, aby sa zabezpečila konzistentnosť. Tento krok je nevyhnutný pre platné vyhodnotenie, pretože odráža podmienky, za ktorých boli modely vyškolené, čím poskytuje spoľahlivé meradlo toho, ako dobre môžu modely fungovať v praktických diagnostických podmienkach. Tento integrovaný prístup k ukladaniu a hodnoteniu modelov zabezpečuje, že každý krok - od školenia modelov po testovanie - prebieha za konzistentných a kontrolovaných podmienok, čím sa zvyšuje spoľahlivosť a presnosť hodnotenia výkonnosti.

#### **5.4.2. Vizualizácia výkonu**

Táto fáza procesu sa sústreďuje na analýzu výkonnostných ukazovateľov modelu a vizuálnu interpretáciu týchto výsledkov, čím poskytuje jasné a komplexné posúdenie účinnosti modelu.

Hodnotenie sa začína generovaním podrobnej klasifikačnej správy pomocou funkcie *classification\_report* z programu *scikit-learn*. Táto správa zostavuje metriky pre každú triedu na základe predpovedí vykonaných modelom na testovacom súbore údajov vrátane precíznosti, spätnej väzby a skóre F1. Tieto metriky sú veľmi dôležité, pretože poskytujú podrobný pohľad na výkon modelu v rôznych klasifikáciách.

*Precíznosť* meria presnosť pozitívnych predpovedí a udáva, koľko z predpovedaných pozitívnych prípadov bolo skutočne pozitívnych.

*Spätná väzba* (Recall) identifikuje schopnosť modelu nájsť všetky relevantné prípady v rámci triedy, čo je kľúčová metrika na zabezpečenie toho, aby sa neprehliadol žiadny významný stav.

*Skóre F1* poskytuje rovnováhu medzi precíznosťou a spätnou väzbou, ktorá je nevyhnutná na posúdenie celkovej účinnosti modelu. Táto rovnováha je obzvlášť dôležitá v oblasti medicíny, kde môže mať vážne dôsledky tak prehliadnutie stavu (nízka recall), ako aj nesprávne diagnostikovanie stavu (nízka precíznosť).

Tieto metriky sa vyberajú nielen preto, aby poskytli ucelený pohľad na schopnosti modelu, ale aj preto, aby sa zabezpečilo, že každé rozhodnutie týkajúce sa jeho nasadenia bude dobre informované. Metriky výkonnosti sú tiež vizuálne znázornené prostredníctvom stĺpcových grafov, ktoré porovnávajú rôzne triedy. Táto vizualizácia nielen kvantitatívne zvyrazňuje výkonnosť modelu, ale slúži aj ako vizuálne zhrnutie, ktoré pomáha efektívne vyhodnotiť silné a slabé stránky modelu.

## 6. Výsledky

### 6.1. Prehľad experimentálnych výsledkov

V tejto kapitole sú uvedené výsledky série experimentov vykonaných s cieľom vyhodnotiť účinnosť techník hlbokého učenia pri zlepšovaní klasifikácie röntgenových snímok. Na základe metodík podrobne opísaných v kapitole 4 boli tieto experimenty navrhnuté tak, aby riešili kritické výzvy v oblasti lekárskeho zobrazovania, najmä nevyváženosť tried a obmedzenia vyplývajúce z typicky malého rozsahu anotovaných súborov lekárskeho údajov.

Výskum bol štruktúrovaný do troch kľúčových skúmaní:

- Použitie váh tried na zlepšenie objektívnosti a presnosti modelu v rôznych triedach, najmä so zameraním na tie, ktoré sú v tréningových súboroch údajov nedostatočne zastúpené. Tento prístup testuje hypotézu, že vyváženie vplyvu jednotlivých tried vedie k presnejšej diagnostike.
- Vplyv rôznych techník rozšírenia údajov na výkonnosť modelu, pričom sa posudzuje, ako rôzne úpravy trénovaných údajov ovplyvňujú schopnosť CNN zovšeobecniť na nové, nevidené obrázky. Cieľom tohto experimentu je zvýšiť robustnosť modelu, ktorá je kľúčovým faktorom v reálnych lekárske aplikáciách.
- Porovnávací analýza modelov natrénovaných s pôvodnými súbormi údajov v porovnaní s modelmi natrénovanými s pôvodnými aj rozšírenými údajmi, ktorej cieľom je určiť celkové výhody začlenenia rozšírených údajov do procesu tréningu. Cieľom tohto porovnania je overiť účinnosť rozšírenia pri prekonávaní obmedzení súboru údajov.

Každý z týchto experimentov bol zameraný na zvýšenie robustnosti a diagnostickej presnosti CNN používaných v lekárske zobrazovaní. Zistenia z týchto experimentov sú rozhodujúce pri navrhovaní, ako by sa hlboké učenie mohlo efektívnejšie nasadiť na zlepšenie presnosti a spoľahlivosti diagnostických procesov v zdravotníckych zariadeniach.

### 6.2. Experiment 1 - Účinnosť váh tried

Hlavným cieľom tohto experimentu bolo zistiť, či by implementácia váh tried mohla účinne vyriešiť problém nevyváženosti tried v rámci súborov röntgenových snímok. Hypotéza bola, že váhy tried zlepšia presnosť modelu tým, že zvýšia jeho schopnosť správne klasifikovať nedostatočne zastúpené triedy.


Váhy tried boli vypočítané a použité na riešenie nevyváženosti tried v súboroch údajov röntgenových snímok. Tieto váhy zabezpečili cielené tréňovanie na menej časté triedy, keďže priamo súviseli s frekvenciou tried v tréňovaných údajoch. Stratová funkcia modelu sa potom počas tréňovania upravila tak, aby zahŕňala vypočítané váhy, čo model motivovalo k tomu, aby uprednostnil presnosť v nedostatočne zastúpených triedach. Táto stratégia sa riešením nerovnováhy zameriava na zlepšenie celkových diagnostických schopností modelu.

Účinnosť váh tried sa hodnotila v troch rôznych architektúrach hlbokého učenia pri klasifikácii röntgenových snímok vybraných zo súboru trinástich testovaných modelov. Vybrané modely - EfficientNetB2, DenseNet201 a InceptionResNetV2

EfficientNetB2, známy svojou vysokou základnou presnosťou, preukázal celkové zlepšenie presnosti o 2,74 % po implementácii váh tried. Najmä presnosť v triede 13 (Bederná časť chrbtice) zaznamenala zlepšenie z 90,91% na 95,24% , čo poukazuje na potenciál váh tried na ďalšie doladenie vysoko výkonných modelov. Toto zlepšenie podčiarkuje užitočnosť váh tried pri zvyšovaní presnosti tried, ktoré už dosahujú dobré výsledky, ale na dosiahnutie optimálnych výsledkov by mohli ešte využiť jemné úpravy.

DenseNet201, ďalší vysoko výkonný model s odlišnou architektúrou od modelu EfficientNet, vykazoval 6,65 % nárast priemernej presnosti. Najmä v prípade triedy 4 (Kľúčna kosť) sa jej presnosť dramaticky zvýšila z 33,33% na 88,89% , čo dokazuje vplyv váh tried na triedy, ktoré mali pôvodne slabú mieru rozpoznávania. Toto výrazné zlepšenie ilustruje, ako môžu váhy tried výrazne zvýšiť citlivosť modelu na prvky v triedach, ktoré sú menej zastúpené alebo ktorých identifikácia je náročnejšia z dôvodu nerovnováhy.

InceptionResNetV2 bol vybraný pre svoju pôvodne nižšiu presnosť, čo poskytlo príležitosť otestovať, či váhy tried môžu výrazne prospieť modelom, ktoré si vyžadujú výraznejšie zlepšenie. Tento model vykázal najvýraznejšie zlepšenie, pričom celková presnosť sa zvýšila o 8,32 %. Pozoruhodné je, že trieda 18 (Lebka), ktorej počiatočná presnosť bola 0% , sa po použití váh tried zlepšila na 75% . Toto zlepšenie nielenže poukazuje na dramatický vplyv, ktorý môžu mať váhy tried na zvýšenie výkonnosti modelu pre nedostatočne zastúpené triedy, ale naznačuje aj potenciál transformácie slabých výkonných modelov na spoľahlivejšie nástroje pre lekársku diagnostiku.



Obrázok 15- Porovnanie výkonnosti rôznych architektúr neurónových sietí v experimente 1: Tento graf zobrazuje presnosť klasifikácie troch modelov neurónových sietí - DenseNet201, EfficientNetB2 a InceptionResNetV2 - za dvoch podmienok: s použitím pôvodných nastavení (červená čiara) a po použití úprav váh tried (fialová čiara). zdroj: autor

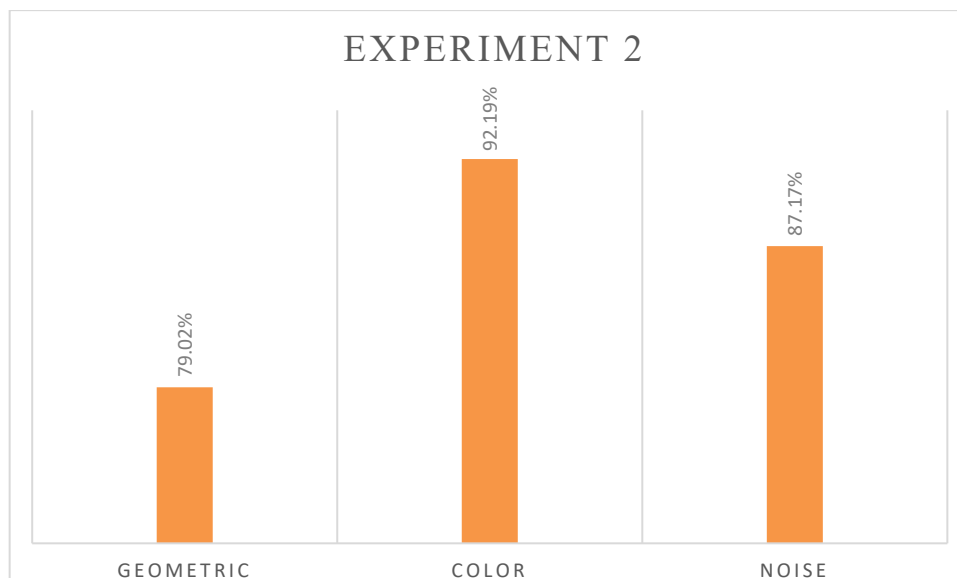
Výsledky experimentu (Obr. 15) naznačujú, že váhy tried pozitívne ovplyvnili výkonnosť modelov hlbokého učenia, najmä v prípade modelov, ktoré mali spočiatku problémy s konkrétnymi triedami. Tento účinok však nebol rovnomerný; rôzne modely a triedy zaznamenali rôzny stupeň zlepšenia.

Praktické dôsledky pre lekársku diagnostiku, hoci nie sú primárnym cieľom tohto výskumu, naznačujú, že starostlivo upravené váhy tried by potenciálne mohli viesť k presnejšej detekcii zriedkavých stavov. To je vzhľadom na vysoké nároky na lekársku zobrazovaciu diagnostiku veľmi dôležité.

### 6.3. Experiment 2 - Vplyv techník augmentácie údajov

Hlavným cieľom tohto experimentu bolo posúdiť, ako rôzne techniky rozšírenia údajov - konkrétne geometrické transformácie, úpravy farieb a pridávanie šumu - ovplyvňujú výkon modelov CNN. Cieľom bolo určiť, ktoré typy rozšírenia najúčinnnejšie zvyšujú robustnosť a zovšeobecňujúce schopnosti modelov.

Tento experiment, ktorý sa zameriava na základné stratégie rozšírenia údajov podrobne opísané v kapitole 4, zahŕňal tréňovanie modelov CNN výlučne na rozšírených súboroch údajov. Implementované rozšírenia - geometrické transformácie, úpravy farieb a pridávanie šumu - boli vybrané tak, aby boli výzvou pre adaptáciu modelov a schopnosti učenia a poskytli prehľad o účinnosti jednotlivých typov rozšírení.



Obrázok 16- Účinnosť rôznych techník rozšírenia údajov v experimente 2: stĺpcový graf znázorňuje vplyv troch typov techník rozšírenia údajov - geometrických, farebných a šumových- na výkonnosť modelu. zdroj: autor

Výsledky (Obr. 16) ukázali, že úpravy farieb mali najvýraznejší vplyv na výkonnosť modelov, čo naznačuje, že tieto vlastnosti sú rozhodujúce pre správnu klasifikáciu röntgenových snímok. Pridanie šumu bolo tiež prospešné, hoci v menšej miere, čo naznačuje jeho úlohu pri pomoci modelom rozoznať signál od šumu. Naopak najmenší vplyv mali geometrické transformácie, čo naznačuje potenciálne problémy so zosúladením s klinickými odchýlkami, ktoré sú v údajoch prirodzene prítomné.

Pozitívny vplyv rozšírenia údajov na modely CNN bol zrejmý najmä vďaka zvýšenej variabilite a objemu trénovaných údajov. Použitie týchto techník priamo rieši problémy spojené s nedostatkom a rôznorodosťou údajov, ktoré sú nevyhnutné na vývoj spoľahlivých diagnostických nástrojov.

Farebné úpravy sa ukázali ako najefektívnejšie, pravdepodobne preto, že zlepšujú kritické prvky v odtieňoch šedej, ktoré sú nositeľmi významných diagnostických informácií na röntgenových snímkach. Zdá sa, že tento typ rozšírenia doladuje citlivosť modelov na jemné odchýlky svedčiacie o zdravotných stavoch.

Geometrické transformácie na druhej strane priniesli najmenej výrazné zlepšenia. Vzhľadom na štandardizáciu umiestnenia častí tela na röntgenových snímkach môžu razantné geometrické zmeny narušiť priestorové vlastnosti, na ktoré sa modely spoliehajú pri presnej klasifikácii. To zdôrazňuje dôležitosť kontextu pri výbere techník rozšírenia - to, čo prospieva prirodzenému spracovaniu obrazu, sa nemusí priaznivo prejavovať pri lekárskej zobrazovaní, kde je rozhodujúca presnosť umiestnenia anatomických štruktúr.

Účinnosť pridávania šumu naznačuje, že modely sa môžu naučiť odolnosti voči artefaktom, ktoré sa bežne vyskytujú v klinických podmienkach. Príliš veľké množstvo šumu však môže byť škodlivé a zatieniť dôležité vlastnosti, čo zdôrazňuje potrebu vyváženého prístupu k rozširovaniu.

Experiment v konečnom dôsledku zdôrazňuje potenciál rozšírenia údajov nielen ako nástroja na riešenie obmedzení údajov, ale aj ako prostriedku na podstatné zlepšenie robustnosti a presnosti CNN v lekárskom zobrazovaní.

## **6.4. Experiment 3 - Porovnávací analýza tréningu na pôvodných vs. pôvodných + rozšírených údajoch**

Účelom tohto experimentu je zistiť, či začlenenie rozšírených údajov do pôvodných súborov údajov môže zvýšiť výkon a zovšeobecnenie modelov CNN v kontextoch s nevyváženými triedami a obmedzenou dostupnosťou údajov. Cieľom je posúdiť, ako rozšírené údaje ovplyvňujú diagnostickú presnosť a spoľahlivosť modelov v lekárskom zobrazovaní.

Tento experiment využíva techniky rozšírenia skúmané v experimente 2 - vrátane geometrických transformácií, úprav farieb a pridávania šumu - a porovnáva výkon modelov CNN na dvoch súboroch údajov. Prvý súbor údajov pozostávajúci výlučne z pôvodných obrázkov bol pripravený so špecifickým rozdelením: 5 vzoriek na triedu na testovanie, 2 na overenie a zvyšok na tréning. Druhý súbor údajov spájal tieto pôvodné obrázky s ich rozšírenými ekvivalentmi a bol rozdelený pomocou štandardného rozdelenia: 80 % na tréning, 10 % na validáciu a 10 % na testovanie.


Modely CNN použité v tejto analýze boli vybrané na základe ich výkonu v experimente 1. Dva modely, ktoré vykazovali sľubné výsledky, boli vybrané na preskúmanie možných ďalších zlepšení pomocou rozšíreného tréningu a jeden model, ktorý mal slabé výsledky, bol zaradený na otestovanie, či by rozšírenie mohlo výrazne zvýšiť jeho presnosť. Tento prístup poskytuje komplexné posúdenie toho, ako rozšírenie ovplyvňuje modely s rôznou počiatočnou úrovňou výkonnosti, a ponúka pohľad na potenciál rozšíreného tréningu na účinné riešenie problémov nedostatku údajov a nerovnováhy tried.

Porovnávacia analýza modelov CNN natrénovaných na pôvodných a rozšírených súboroch údajov ukázala pozoruhodné zistenia.

DenseNet201, ktorý predtým vykazoval priemernú presnosť 66,58 %, zaznamenal pozoruhodný nárast na 90,95 %, keď bol trénovaný na kombinovanom pôvodnom a rozšírenom súbore údajov. Toto výrazné zlepšenie naznačuje, že techniky rozšírenia poskytnú modelu širšie spektrum funkcií, ktoré sa mal naučiť, čím sa zvýšila jeho schopnosť zovšeobecnenia, a tým sa výrazne zlepšila jeho presnosť.

EfficientNetB2 tiež profitoval z rozšíreného tréningu, pričom jeho priemerná presnosť sa zvýšila zo 73,40 % na 96,05 %. Tento model, ktorý už patril k tým výkonnejším, preukázal ešte väčší potenciál s obohateným súborom údajov, čo naznačuje, že rozšírenie môže ďalej zdokonaľiť diagnostickú presnosť modelu.

InceptionResNetV2 vykázal najvýraznejšie zlepšenie; z najmenej presného modelu s priemernou presnosťou 53,02 % sa s rozšíreným tréningom vyšplhal na 89,87 % presnosť. To zdôrazňuje potenciál rozšírenia údajov pri zvyšovaní výkonnosti modelov, ktoré majú spočiatku problémy so správnou klasifikáciou obrázkov.



Obrázok 17 - Porovnávacia analýza výkonnosti modelu s a bez rozšírenia údajov v experimente 3: Tento graf porovnáva účinnosť použitia samotných pôvodných trénovaných údajov v porovnaní s ich kombináciou s rozšírením údajov pre tri architektúry neurónových sietí - DenseNet201, EfficientNetB2 a InceptionResNetV2. zdroj: autor



Vo všetkých modeloch prinieslo tréovanie na rozšírenom súbore údajov jasné zlepšenie výkonnostných ukazovateľov. Pozorované prírastky potvrdzujú hypotézu, že rozšírenie údajov môže účinne riešiť obmedzenia spôsobené nevyváženými a nedostatočnými tréningovými údajmi, ktoré sú často problémom v lekárskej obrazovej diagnostike. Toto zlepšenie je veľmi dôležité vzhľadom na vysokú mieru rizika v lekárskej diagnostike, kde každé percento zvýšenia presnosti môže významne ovplyvniť výsledky pacientov.

Výsledky tohto experimentu (Obr. 17) ukazujú, že investovanie dodatočného času do tréningu modelov CNN na rozšírených údajoch vedie k výraznému zlepšeniu presnosti klasifikácie častí tela na základe röntgenových snímok. To naznačuje, že rozšírený prístup je napriek predĺženému trvaniu tréningu cenný, najmä v podmienkach s nevyváženými alebo obmedzenými súbormi údajov. Pokroky vo výkonnosti modelov naznačujú, že takéto modely by sa mohli efektívne využívať v klinickej praxi na pomoc pri presnej kategorizácii röntgenových snímok, čím by sa podporili zdravotnícki pracovníci v diagnostických procesoch.

## 7. Diskusia

Táto práca preukázala rozhodujúcu úlohu špecifických stratégií hlbokého učenia pri zlepšovaní klasifikácie röntgenových snímok prostredníctvom aplikácie konvolučných neurónových sietí (CNN). Metodickým zdokonaľovaním procesov tréovania a úpravou parametrov modelu výskum výrazne posunul praktické a teoretické chápanie analýzy medicínskych snímok.

Experiment 6.2 poukázal na to, ako môže použitie váhy tried účinne riešiť nerovnováhu tried, čím sa výrazne zvýši presnosť modelu. Tento experiment ukázal, že modely môžu dosiahnuť lepšiu presnosť, keď sa proces tréovania prispôsobí frekvencii výskytu tried.

V experimente 6.3 sa skúmali účinky rôznych techník rozšírenia údajov, pričom ako mimoriadne vplyvné sa ukázali úpravy farieb. Toto prispôsobenie je kľúčové pre röntgenovú diagnostiku, kde môže byť presná interpretácia snímok v odtieňoch šedej kľúčová.

Experiment 6.4 zdôraznil výhody začlenenia rozšírených súborov údajov do tréningového režimu. Ukázalo sa, že modely natréované na kombinácii pôvodných a rozšírených údajov nielenže dosahovali lepšie výsledky, ale vykazovali aj lepšie schopnosti zovšeobecňovania v rámci nepozorovaných údajov.

Tieto zistenia majú zásadný význam pre oblasť lekárskej diagnostiky. Integráciou sofistikovaných techník spracovania údajov a využitím pokročilých stratégií tréovania neurónových sietí je možné výrazne zvýšiť presnosť a spoľahlivosť diagnostických nástrojov. Tieto zlepšenia by mohli viesť k efektívnejším plánom liečby pacientov a potenciálne zachrániť životy poskytnutím presnejších diagnostických informácií.

Trajektória naznačená v tomto výskume naznačuje sľubnú budúcnosť, v ktorej sú zdokonalené CNN neoddeliteľnou súčasťou lekárskej zobrazovacej diagnostiky. Pokračovanie v skúmaní optimalizácie týchto modelov môže ďalej zdokonaľiť ich účinnosť a efektívnosť, čím sa stanú nenahraditeľnými nástrojmi v klinických podmienkach.

## 8. Záver

Výskum uskutočnený v tejto práci potvrdzuje výrazný vplyv cielených výpočtových techník na výkonnosť CNN používaných na klasifikáciu medicínskych obrazov. Strategické použitie váh tried a rozšírenie údajov nielenže vyriešilo kritické problémy, ako je nedostatok údajov a nevyváženosť tried, ale tiež pripravilo cestu pre implementáciu týchto modelov v reálnych diagnostických procesoch.

Hoci vykonané experimenty poskytujú podstatné dôkazy o výhodách týchto metód, poukazujú aj na obmedzenia vlastné každej vedeckej štúdií, ako je špecifickosť súborov údajov a potenciálna potreba širšej validácie v rôznych lekárskejších kontextoch.

Budúci výskum by sa mohol zamerať na rozšírenie použiteľnosti týchto zistení prostredníctvom širšej integrácie súborov údajov a skúmania ďalších techník rozšírenia, ktoré by mohli presnejšie napodobniť klinické rozdiely. Existuje tiež významná príležitosť na využitie novších, výkonnejších výpočtových architektúr, ktoré by mohli ďalej zlepšiť diagnostické schopnosti CNN. Okrem toho by vývoj užívateľsky prívetivého grafického používateľského rozhrania (GUI) alebo integrácia týchto modelov do mobilnej alebo webovej aplikácie mohli výrazne zvýšiť ich využiteľnosť v klinických podmienkach. Sprístupnením modelov prostredníctvom aplikácie by mohli zdravotníci pracovníci používať tieto pokročilé diagnostické nástroje priamo v nemocniciach a na klinikách, čo by uľahčilo rozhodovanie v reálnom čase a zlepšilo starostlivosť o pacientov. Takýto vývoj aplikácie by nielen zlepšil dostupnosť týchto modelov, ale zabezpečil by aj ich praktickosť a účinnosť v reálnom lekárskom prostredí.

Celkovo táto práca prispieva nielen do akademickéj oblasti, ale stanovuje aj praktický rámec pre budúci pokrok, ktorý by mohol spôsobiť revolúciu v lekárskej diagnostike. Integrácia hlbokého učenia do medicínskeho zobrazovania ponúka sľubnú cestu na zlepšenie poskytovania zdravotnej starostlivosti, čo podčiarkuje hodnotu a potenciál tohto výskumu.

## Zoznam použitej literatúry

- [1] LITJENS, Geert, Thijs KOOI, Babak Ehteshami BEJNORDI, Arnaud Arindra Adiyoso SETIO, Francesco CIOMPI, Mohsen GHAFORIAN, Jeroen A. W. M. VAN DER LAAK, Bram VAN GINNEKEN a Clara I. SÁNCHEZ. A survey on deep learning in medical image analysis. *Medical Image Analysis* [online]. 2017, **42**, 60–88. ISSN 1361-8415. Dostupné z: doi:10.1016/j.media.2017.07.005
- [2] PANCHBHAI, Arati S. Wilhelm Conrad Röntgen and the discovery of X-rays: Revisited after centennial. *Journal of Indian Academy of Oral Medicine and Radiology* [online]. 2015, **27**(1), 90. ISSN 0972-1363. Dostupné z: doi:10.4103/0972-1363.167119
- [3] *Über Röntgen – Röntgen-Gedächtnisstätte* [online]. [vid. 2024-04-25]. Dostupné z: <https://wilhelmconradroentgen.de/de/ueber-roentgen>
- [4] FRANKEL, R I. Centennial of Röntgen's discovery of x-rays. *Western Journal of Medicine*. 1996, **164**(6), 497–501. ISSN 0093-0415.
- [5] HENDEE, William R. Physics and applications of medical imaging. *Reviews of Modern Physics* [online]. 1999, **71**(2), S444–S450. Dostupné z: doi:10.1103/RevModPhys.71.S444
- [6] RAKSHA, D. S. CT Scans VS MRI Scans: What are the Differences Between Them. *Kiran Lab* [online]. 14. červenec 2023 [vid. 2024-04-25]. Dostupné z: <https://kiranpetct.com/ct-scans-vs-mri-scans-what-are-the-differences-between-them/>
- [7] HARVEY, Christopher J., James M. PILCHER, Robert J. ECKERSLEY, Martin J. K. BLOMLEY a David O. COSGROVE. Advances in Ultrasound. *Clinical Radiology* [online]. 2002, **57**(3), 157–177. ISSN 0009-9260. Dostupné z: doi:10.1053/crad.2001.0918
- [8] SONOGRAPHICTENDENCIES. Chest and Lung Ultrasound. *Sonographic Tendencies* [online]. 18. březen 2020 [vid. 2024-04-25]. Dostupné z: <https://sonographictendencies.com/2020/03/18/chest-and-lung-ultrasound/>
- [9] ISHIGAKI, Takeo, Mitsuru IKEDA, Kazuhiro SHIMAMOTO, Hideki HIROTA a Naoki MAKINO. Digital radiology and PACS. *Nagoya journal of medical science*. 1993, **56**, 53–67.
- [10] BHADORIA, Sonali a C.G. DETHE. Study of Medical Image Retrieval. In: *2010 International Conference on Data Storage and Data Engineering: 2010 International Conference on Data Storage and Data Engineering* [online]. 2010, s. 192–196 [vid. 2024-04-15]. Dostupné z: doi:10.1109/DSDE.2010.55
- [11] HAINS, Isla M., Andrew GEORGIU a Johanna I. WESTBROOK. The impact of PACS on clinician work practices in the intensive care unit: a systematic review of the literature. *Journal of the American Medical Informatics Association : JAMIA* [online]. 2012, **19**(4), 506. Dostupné z: doi:10.1136/amiajnl-2011-000422
- [12] BLINOV, N. N., E. B. KOZLOVSKII a O. V. ROMANOV. A New Stage for Standardization of Medical X-Ray Equipment. *Biomedical Engineering* [online]. 2014, **47**(5), 241–242. ISSN 1573-8256. Dostupné z: doi:10.1007/s10527-014-9380-y

- [13] VENKATARAMAN, Viswanathan, Travis BROWNING, Ivan PEDROSA, Suhny ABBARA, David FETZER, Seth TOOMAY a Ronald M. PESHOCK. Implementing Shared, Standardized Imaging Protocols to Improve Cross-Enterprise Workflow and Quality. *Journal of Digital Imaging* [online]. 2019, **32**(5), 880. Dostupné z: doi:10.1007/s10278-019-00185-4
- [14] BRUNO, Michael A., Eric A. WALKER a Hani H. ABUJUDEH. Understanding and Confronting Our Mistakes: The Epidemiology of Error in Radiology and Strategies for Error Reduction. *RadioGraphics* [online]. 2015, **35**(6), 1668–1676. ISSN 0271-5333. Dostupné z: doi:10.1148/rg.2015150023
- [15] DAGVASUMBEREL, Gonchigsuren, Bayarbaatar BOLD a Munkhbaatar DAGVASUMBEREL. The Growing Problem of Radiologist Shortage: Mongolia's Perspective. *Korean Journal of Radiology* [online]. 2023, **24**(10), 938–940. ISSN 1229-6929. Dostupné z: doi:10.3348/kjr.2023.0787
- [16] RAMLI, Norlisah Mohd a Norzaini Rose MOHD ZAIN. The Growing Problem of Radiologist Shortage: Malaysia's Perspective. *Korean Journal of Radiology* [online]. 2023, **24**(10), 936–937. ISSN 1229-6929. Dostupné z: doi:10.3348/kjr.2023.0742
- [17] *Deep Learning Applications in Medical Image Analysis | IEEE Journals & Magazine | IEEE Xplore* [online]. [vid. 2024-04-15]. Dostupné z: <https://ieeexplore.ieee.org/document/8241753>
- [18] LANGER, Steve G. Challenges for Data Storage in Medical Imaging Research. *Journal of Digital Imaging* [online]. 2011, **24**(2), 203–207. ISSN 0897-1889. Dostupné z: doi:10.1007/s10278-010-9311-8
- [19] JAN, Bilal, Haleem FARMAN, Murad KHAN, Muhammad IMRAN, Ihtesham Ul ISLAM, Awais AHMAD, Shaukat ALI a Gwanggil JEON. Deep learning in big data Analytics: A comparative study. *Computers & Electrical Engineering* [online]. 2019, **75**, 275–287. ISSN 0045-7906. Dostupné z: doi:10.1016/j.compeleceng.2017.12.009
- [20] SPERLING, Ed. Deep Learning Spreads. *Semiconductor Engineering* [online]. 31. leden 2018 [vid. 2024-04-25]. Dostupné z: <https://semiengineering.com/deep-learning-spreads/>
- [21] ZHANG, Qingchen, Laurence T. YANG, Zhikui CHEN a Peng LI. A survey on deep learning for big data. *Information Fusion* [online]. 2018, **42**, 146–157. ISSN 1566-2535. Dostupné z: doi:10.1016/j.inffus.2017.10.006
- [22] LI, Zewen, Fan LIU, Wenjie YANG, Shouheng PENG a Jun ZHOU. A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *IEEE Transactions on Neural Networks and Learning Systems* [online]. 2022, **33**(12), 6999–7019. ISSN 2162-2388. Dostupné z: doi:10.1109/TNNLS.2021.3084827
- [23] RAKHLIN, Alexander. *Diabetic Retinopathy detection through integration of Deep Learning classification framework* [online]. B.m.: bioRxiv. 19. červen 2018 [vid. 2024-04-15]. Dostupné z: doi:10.1101/225508
- [24] SHEN, Li, Laurie R. MARGOLIES, Joseph H. ROTHSTEIN, Eugene FLUDER, Russell MCBRIDE a Weiva SIEH. Deep Learning to Improve Breast Cancer Detection on Screening Mammography. *Scientific Reports* [online]. 2019, **9**(1), 12495. ISSN 2045-2322. Dostupné z: doi:10.1038/s41598-019-48995-4

- [25] CHEN, Chen, Chen QIN, Huaqi QIU, Giacomo TARRONI, Jinming DUAN, Wenjia BAI a Daniel RUECKERT. Deep Learning for Cardiac Image Segmentation: A Review. *Frontiers in Cardiovascular Medicine* [online]. 2020, 7 [vid. 2024-04-15]. ISSN 2297-055X. Dostupné z: doi:10.3389/fcvm.2020.00025
- [26] Explainable Deep Learning Models for Healthcare Decision Support. *International Journal of Advances in Computer Science and Technology* [online]. 2023, 12(10), 63–69. ISSN 23202602. Dostupné z: doi:10.30534/ijacst/2023/0112102023
- [27] Article Detail. *International Journal of Advanced Research* [online]. [vid. 2024-04-15]. Dostupné z: <https://www.journalijar.com/article/>
- [28] KHAN, Asifullah, Anabia SOHAIL, Umme ZAHORA a Aqsa Saeed QURESHI. A survey of the recent architectures of deep convolutional neural networks. *Artificial Intelligence Review* [online]. 2020, 53(8), 5455–5516. ISSN 1573-7462. Dostupné z: doi:10.1007/s10462-020-09825-6
- [29] Basic CNN Architecture: Explaining 5 Layers of Convolutional Neural Network. *upGrad blog* [online]. [vid. 2024-04-27]. Dostupné z: <https://www.upgrad.com/blog/basic-cnn-architecture/>
- [30] *Review of Deep Learning Algorithms and Architectures | IEEE Journals & Magazine | IEEE Xplore* [online]. [vid. 2024-04-16]. Dostupné z: <https://ieeexplore.ieee.org/document/8694781>
- [31] ALFAHDAWI, Mohammed Gharkan, Khattab M Ali ALHEETI a Salah Sleibi AL-RAWI. Object Recognition System for Autonomous Vehicles Based on PCA and 1D-CNN. In: *2021 7th International Conference on Contemporary Information Technology and Mathematics (ICCITM): 2021 7th International Conference on Contemporary Information Technology and Mathematics (ICCITM)* [online]. 2021, s. 219–225 [vid. 2024-04-16]. Dostupné z: doi:10.1109/ICCITM53167.2021.9677676
- [32] SHIN, Hoo-Chang, Holger R. ROTH, Mingchen GAO, Le LU, Ziyue XU, Isabella NOGUES, Jianhua YAO, Daniel MOLLURA a Ronald M. SUMMERS. Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning. *IEEE Transactions on Medical Imaging* [online]. 2016, 35(5), 1285–1298. ISSN 1558-254X. Dostupné z: doi:10.1109/TMI.2016.2528162
- [33] SAXENA, Akarsh. Building a Simple Neural Network from Scratch. *Medium* [online]. 2. červen 2020 [vid. 2024-04-27]. Dostupné z: <https://towardsdatascience.com/building-a-simple-neural-network-from-scratch-a5c6b2eb0c34>
- [34] CHEN, Leiyu, Shaobo LI, Qiang BAI, Jing YANG, Sanlong JIANG a Yanming MIAO. Review of Image Classification Algorithms Based on Convolutional Neural Networks. *Remote Sensing* [online]. 2021, 13(22), 4712. ISSN 2072-4292. Dostupné z: doi:10.3390/rs13224712
- [35] ABDELHAMID MAHRI UNIVERSITY, ALGERIA, Sara SABBA, Meroua SMARA, ABDELHAMID MAHRI UNIVERSITY, ALGERIA, Mehdi BENHACINE, ABDELHAMID MAHRI UNIVERSITY, ALGERIA, Loubna TERRA, ABDELHAMID MAHRI UNIVERSITY, ALGERIA, Zine EDDINE TERRA, a ABDELHAMID MAHRI UNIVERSITY, ALGERIA. Residual Neural Network in Genomics. *Computer Science Journal of Moldova* [online]. 2022, 30(3(90)), 308–334. ISSN 15614042, 25874330. Dostupné z: doi:10.56415/csjm.v30.17

- [36] BRITAL, Anas. Residual Networks With Examples. *Medium* [online]. 28. říjen 2021 [vid. 2024-04-27]. Dostupné z: <https://medium.com/@AnasBrital98/residual-networks-with-examples-80b47cacecf4>
- [37] *U-Net and Its Variants for Medical Image Segmentation: A Review of Theory and Applications* | *IEEE Journals & Magazine* | *IEEE Xplore* [online]. [vid. 2024-04-16]. Dostupné z: <https://ieeexplore.ieee.org/document/9446143>
- [38] 42: *A blog on A.I.* [online]. [vid. 2024-04-27]. Dostupné z: [https://nchlis.github.io/2019\\_10\\_30/page.html](https://nchlis.github.io/2019_10_30/page.html)
- [39] AYDIN, Halise Nur a Oktay YILDIZ. Improved ECA-DenseNet Framework for Brain MRI Image Classification. In: *2023 31st Signal Processing and Communications Applications Conference (SIU): 2023 31st Signal Processing and Communications Applications Conference (SIU)* [online]. 2023, s. 1–4 [vid. 2024-04-16]. ISSN 2165-0608. Dostupné z: doi:10.1109/SIU59756.2023.10223886
- [40] CHEN, Zhimei. Hardware Accelerated Optimization of Deep Learning Model on Artificial Intelligence Chip. *Frontiers in Computing and Intelligent Systems* [online]. 2023, **6**(2), 11–14. ISSN 2832-6024. Dostupné z: doi:10.54097/fcis.v6i2.03
- [41] CHEN, Bin, Jiajun WANG a Zheru CHI. Improved DenseNet with Convolutional Attention Module for Brain Tumor Segmentation. In: *Proceedings of the Third International Symposium on Image Computing and Digital Medicine* [online]. New York, NY, USA: Association for Computing Machinery, 2019, s. 22–26 [vid. 2024-04-16]. ISICDM 2019. ISBN 978-1-4503-7262-6. Dostupné z: doi:10.1145/3364836.3364841
- [42] CHLAP, Phillip, Hang MIN, Nym VANDENBERG, Jason DOWLING, Lois HOLLOWAY a Annette HAWORTH. A review of medical image data augmentation techniques for deep learning applications. *Journal of Medical Imaging and Radiation Oncology* [online]. 2021, **65**(5), 545–563. ISSN 1754-9485. Dostupné z: doi:10.1111/1754-9485.13261
- [43] FRID-ADAR, Maayan, Eyal KLANG, Michal AMITAI, Jacob GOLDBERGER a Hayit GREENSPAN. Synthetic data augmentation using GAN for improved liver lesion classification. In: *2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018): 2018 IEEE 15th International Symposium on Biomedical Imaging (ISBI 2018)* [online]. 2018, s. 289–293 [vid. 2024-04-16]. ISSN 1945-8452. Dostupné z: doi:10.1109/ISBI.2018.8363576
- [44] Generative Adversarial Network (GAN). *GeeksforGeeks* [online]. 15. leden 2019 [vid. 2024-04-27]. Dostupné z: <https://www.geeksforgeeks.org/generative-adversarial-network-gan/>
- [45] *The UNIFESP X-Ray Body Part Classification Dataset* [online]. [vid. 2024-04-22]. Dostupné z: <https://www.kaggle.com/datasets/felipekitamura/unifesp-xray-bodypart-classification>

# Zoznam použitých obrázkov

Obrázok 1: Wilhelm Conrad Röntgen [3] .....	7
Obrázok 2: Prvá vytvorená röntgenová snímka [3].....	8
Obrázok 3: Príklad snímky hrudníka CT a MRI [6].....	9
Obrázok 4: Príklad ultrazvuku pľúc [8].....	10
Obrázok 5: Rozdiel medzi hlbokým a strojovým učenie [20].....	16
Obrázok 6: Architektúra CNN modelu [29] .....	20
Obrázok 7: Váhy a odchýlky v neurónoch [33].....	21
Obrázok 8: ResNet model [36] .....	23
Obrázok 9: U-Net model [38].....	23
Obrázok 10: GAN architektúra [44] .....	25
Obrázok 11 Ukážka tried röntgenových snímok z použitého súboru údajov: 1- Lebka (Trieda 18), 2- Ruka (Trieda 9), 3- Chodidlo (Trieda 6), 4- Koleno (Trieda 11) .... zdroj: autor .....	30
Obrázok 12 Kroky predspracovania zdroj: autor.....	38
Obrázok 13 Techniky rozšírenia údajov zdroj: autor .....	39
Obrázok 14 Architektúra vrstiev CNN modelu zdroj: autor .....	43
Obrázok 15- Porovnanie výkonnosti rôznych architektúr neurónových sietí v experimente 1: Tento graf zobrazuje presnosť klasifikácie troch modelov neurónových sietí - DenseNet201, EfficientNetB2 a InceptionResNetV2 - za dvoch podmienok: s použitím pôvodných nastavení (červená čiara) a po použití úprav váh tried (fialová čiara). zdroj: autor.....	49
Obrázok 16- Účinnosť rôznych techník rozšírenia údajov v experimente 2: stĺpcový graf znázorňuje vplyv troch typov techník rozšírenia údajov - geometrických, farebných a šumových- na výkonnosť modelu. zdroj: autor .....	50
Obrázok 17 - Porovnávací analýza výkonnosti modelu s a bez rozšírenia údajov v experimente 3: Tento graf porovnáva účinnosť použitia samotných pôvodných trénovaných údajov v porovnaní s ich kombináciou s rozšírením údajov pre tri architektúry neurónových sietí - DenseNet201, EfficientNetB2 a InceptionResNetV2. zdroj: autor.....	52